

학사학위논문

선대구경 발파 데이터와 인공지능을 활용한 전방  
터널 지질 상태 예측 연구

Assessment of ground condition beyond tunnel  
excavation face using PLHBM data and LSTM

이영훈  
신희지

한양대학교  
자원환경공학과

2021년 3월

# 차 례

차 례 .....	i
List of Figures .....	iii
List of Tables .....	v
국문요지 .....	vi
제 1 장 서 론 .....	1
1.1 연구의 필요성 .....	1
1.2 연구 목적 및 내용 .....	2
제 2 장 문헌 연구 .....	3
2.1 터널 발파원리 .....	3
2.2 선대구경 수평심발 공법 .....	5
2.3 지질 예측 방법 .....	6
2.4 데이터 정규화 .....	7
2.4.1 Min-Max Normalization .....	8
2.4.2 Standardization Normalization .....	8
2.4.3 Robust Normalization .....	9
2.5 활성함수 (Activation Function) .....	10
2.6 인공지능 .....	13
제3장 현장조사 및 데이터 수집 .....	15
3.1 현장소개 .....	15
3.2 데이터 수집 및 소개 .....	16
3.2.1 회전압 및 추진압 데이터 .....	17
3.2.2 천공거리 데이터 .....	17
3.2.3 암반특성 데이터 .....	18
3.3 데이터 전처리 .....	21
3.4 상관분석 .....	22

제4장 LSTM 알고리즘 학습 .....	23
4.1 학습 계획 .....	23
4.2 데이터 가공 .....	23
4.3 데이터 정규화 .....	27
4.4 파라미터 변경에 따른 학습 결과 .....	30
4.4.1 활성함수를 변경했을 때의 학습 결과 .....	30
4.4.2 드랍아웃을 변경했을 때의 학습 결과 .....	32
4.5 최적의 모델을 활용한 학습 결과 .....	33
제5장 결론 .....	35
참고문헌 .....	36

## List of Figures

그림 1 Picture Explanation .....	4
그림 2 선대구경 장비 상세 명칭(백종현 외) .....	5
그림 3 Unnormalized와 Normalized일 때 차이 .....	7
그림 4 Robust Normalization .....	9
그림 5 Sigmoid Function .....	10
그림 6 Derivative Sigmoid Function .....	10
그림 7 Hyperbolic Tangent .....	11
그림 8 Derivative Hyperbolic Tangent .....	11
그림 9 Exponential Linear Unit .....	12
그림 10 Recurrent Neural Network .....	13
그림 11 RNN 구조 .....	14
그림 12 LSTM 구조 .....	14
그림 13 현장 정면 모습 .....	15
그림 14 회전압 데이터 .....	16
그림 15 추진압 데이터 .....	16
그림 16 천공 속도 데이터 .....	16
그림 17 암등급(Rock Grade) .....	19
그림 18 높은 등급의 암반 .....	20
그림 19 낮은 등급의 암반 .....	20
그림 20 회전압, 피드압, 속도 간의 Correlation Coefficient .....	22
그림 21 PLHBM의 원본 위치 데이터 .....	24
그림 22 PLHBM의 가공된 위치 데이터 .....	24
그림 23 와이어의 속도 .....	25
그림 24 이상치를 처리한 와이어의 속도 .....	26
그림 25 정규화를 하지 않은 데이터 .....	27
그림 26 Min-Max Normalization을 한 데이터 .....	27
그림 27 Standardization Normalization을 한 데이터 .....	28

그림 28 Robust Normalization을 한 데이터	28
그림 29 Sigmoid와 Hyperbolic Tangent로 설정했을 때 예측 결과	31
그림 30 Leaky ReLU와 ELU로 설정했을 때 예측 결과	31
그림 31 드랍아웃을 0.5, 0.3으로 설정했을 때 예측 결과	32
그림 32 드랍아웃을 0.2, 0.1로 설정했을 때 예측 결과	32
그림 33 파라미터 튜닝을 한 모델 학습 결과	33

## List of Tables

표 1 빌파공법의 종류 .....	4
표 2 유압센서 제원 .....	17
표 3 와이어 센서 제원 .....	17
표 4 암반특성 데이터 계측장비 제원 .....	18
표 5 암반특성 데이터 판단 기준 .....	19
표 6 정규화에 따른 Loss 결과 .....	29
표 7 Activation Function을 Sigmoid로 설정 .....	30
표 8 Dropout을 변경했을 때 Loss .....	32

## 국문요지

본 연구는 발파공법에 이용되는 선대구경 천공 시 획득 가능한 천공데이터를 기반으로 머신러닝 기법을 활용하여 굴착면 전방 지질 상태를 예측하고자 하였다. 이를 위해 크게 여섯가지 분야로 문헌연구를 진행하였다. 천공데이터 수집을 위해 발파 방법에 대한 사전조사가 필요할 것으로 생각하여 터널 발파원리에 대한 선행연구를 조사하였다. 특히 본 연구에서 사용된 발파공법인 선대구경에 대한 문헌연구도 진행하였다. 본 연구의 궁극적 목적인 전방 지질 예측에 대한 국내외 연구 진행 정도 또한 알아보았으며 진행한 문헌연구를 토대로 인공지능 분석을 진행하기 위해 이에 대한 선행 연구도 습득하였다. 이 부분에서 어떤 방법을 사용하는 것이 해당 데이터에 가장 알맞은 분석 방법인지에 대한 결론을 찾을 수 있었으며, 해당 알고리즘에 대한 상세한 학습을 진행할 수 있었다. 이후 천공데이터 수집을 위해 발파 현장을 선택하고 이에 대한 조사를 진행하였으며, 실제 현장에서 선대구경 장비에 부착한 다양한 센서를 이용해 회전압, 천공 속도, 피드압 등의 천공데이터를 성공적으로 수집하였고 이를 데이터화하였다. 또한 천공壕 내부를 촬영할 수 있는 장비를 도입하여 실제 지질을 확인하고 이를 통해 암반 특성 데이터를 수집하였다. 본 연구에서는 두 데이터 간의 상관관계를 인공지능을 이용해 분석하고자 하였다.

이를 통해 지질탐사 분야에서 인공지능의 활용도를 높이고 전방 지질 예측 방안에 대한 새로운 방법을 제안한다. 연구를 통해 예측한 전방 지질 상태를 이용하여 이를 실제 터널 디자인 및 시공에 활용하고 향후 발전 가능성이 높은 지하세계 개발에 있어서 그 의의를 더하고자 한다. 또한 이를 활용하여 향후 매우 빠르며 경제적이고 안전한 지하개발이 가능할 것이라고 예상한다. 본 연구 이후 지속적으로 다양한 암반에서의 천공데이터와 암반 특성 데이터를 수집할 수 있다면 어떤 상황에서도 정확한 지질값을 예측할 수 있는 프로그램 제작이 가능할 것이라 기대한다.

# 제1장 서 론

## 1.1 연구의 필요성

급격한 경제성장과 함께 늘어나는 교통 수요 및 지상 공간 확보를 위해 지하공간의 중요성이 나날이 증가하고 있다. 터널의 시공 중에는 지반붕괴 등의 안전사고를 예방하는 것이 매우 중요하며, 따라서 전방 지질을 예측하는 방법에 대한 기술적인 연구가 다양한 방향으로 진행되고 있다. 특히 터널시공 시 가장 경제적이고 효율적인 발파공법을 주로 사용하는 우리나라에서는 장약공을 천공하기 위해 사용하는 점보드릴을 활용한 연구가 많이 진행되어왔다.

굴착 대상 암반 특성을 파악하기 위해 점보드릴을 사용하여 천공데이터를 수집하는 연구가 지속되어 왔다. 이에 대한 전반적인 방향성을 알아보고자 선행논문을 조사했다. 현재 국내에서는 점보드릴의 회전압, 피드압, 타격압 등을 통해 전방의 암반을 예측할 수 있는 방안이 제시되거나(김광염 외, 2008) RMR<sub>30</sub>과 실제 지반의 상관정도를 천공속도로 분석하는 방법(김해만 외, 2019)이 제안되었다. 점보드릴은 주로 장약공을 천공하거나 심발발파 중에서도 데이터셋이나 parrel cut, v-cut 등에 사용된다. 이를 모두 다 제어발파를 위한 방법이나, 지금까지 점보드릴에만 다양한 연구가 진행되어있다. 같은 제어발파 공법인 선대구경에 대한 연구는 이루어지지 않았다. 게다가, 점보드릴을 이용하여 발파를 하게 되면 한 번에 진행할 수 있는 천공길이가 길지 않다는 단점이 있다. 이러한 단점은 전방지질에 대한 대응성을 감소시켜 지질 예측 연구의 의미성을 축소시킬 수 있다.

따라서 기존연구의 단점을 극복하기 위해 본 연구는 선대구경발파공법에 대한 전방지질 예측 방안을 제안한다. 선대구경발파공법(PLHBM)은 굴착면 전방으로 10~60m 정도 선진 보링한 직경 250~1,000mm의 대수경 수평보링공을 심발 발파시 무장약공으로 활용하는 터널 발파 공법이다. 선대구경을 사용하면 천공길이가 50m에 다다르기 때문에 한 번에 파악할 수 있는 지반 데이터 양이 많아진다. 긴 천공거리를 가진 장비가 전방지질예측기술이 가지는 의미성을 강조할 수 있다. 추가적으로, 선대구경발파공법을 사용하면 천공 구멍 자체가 크기 때문에 영상촬영 등의 추가적인 작업이 가능하다는 이점도 있다. 이러한 이점은 실제 연구에서 암반특성 데이터 등을 수집하는데 큰 도움이 된다.

## 1.2 연구 목적 및 내용

본 연구는 최신의 발파공법 중 하나인 PLHBM(선대구경발파공법)을 사용할 때 획득할 수 있는 천공데이터들을 인공지능으로 분석하여 전방지질을 예측하는 방법에 대해 제안한다.. 선대구경발파공법이란 이전 공법의 단점을 보완하며 소음, 진동의 최소화를 동시에 달성하기 위해 사용하는 최신의 발파기술이다. 연구는 획득한 천공데이터를 바탕으로 굴진 대상의 암반 상태를 예측하며 PLHBM의 새로운 활용 가능성을 제안하는 것을 주요한 목적으로 한다. 이를 위하여 본 논문은 크게 4가지로 구성된다.

- (1) 문헌연구
- (2) 현장조사 및 데이터수집
- (3) LSTM 알고리즘 학습
- (4) 결론

문헌연구를 통해 현장에서 전방지질예측 기술에 대한 선행연구를 학습하고 연구의 방향성을 확실시하였다. 또한 현장조사 및 데이터수집을 통해 본 연구에 필요한 데이터를 수집하고 해당 데이터를 수집한 현장에 대한 지질학적 조사를 진행했다. 데이터수집을 위해 PLHBM에 부착한 센서를 통해 회전압, 피드압, 위치기반 천공 속도를 측정하여 천공 데이터를 획득했다. 이때 선진보링한 천공 내부 영상에서 얻어진 이미지(Borehole Image)로 전방 암반의 상태를 4가지로 분류하여 라벨링 데이터를 만들었다. 이후 얻어진 천공데이터와 라벨링 데이터 간의 연관성을 분석하여 어떤 데이터가 암반 상태를 확인하는데 가장 적합할지 확인하였으며 이후 천공데이터를 input layer, 라벨링 데이터를 output layer로 설정하여 model setting을 진행하였다. 수집한 두 가지의 데이터를 바탕으로 LSTM 학습을 진행하였으며 도출된 결과를 통해 전방지질예측에 대한 정확도와 가능성을 평가하여 결론으로 작성하였다. 이렇듯 본 연구를 통해 전방지질예측에 대한 새로운 패러다임을 제시하고 천공 탐사에서의 적용 가능성을 제안하고자 한다.

## 제2장 문현 연구

### 2.1 터널 발파원리

굴착 방법으로는 크게 기계굴착, 발파굴착이 대표적이다. 때에 따라 2가지 이상의 방법을 혼용하여 사용하는 경우도 존재한다. 기계식 굴착공법은 TBM(Tunnel Boring Machine), 굴착기 등을 이용하여 굴착하는 방법이다. 안전한 쟁내작업이 가능하고 진동이나 폭음이 다른 굴착 공법에 비해 적으며 정확한 원형 단면 절취가 가능하다는 장점이 있어 사용이 증가하고 있다. 그러나 굴착시 사용되는 기계가 중량이 클 뿐만 아니라 굴착 조건에 최적화를 위해 주문제작형식으로 만들어져 타 현장에서의 재사용이 불가능하고, 경제적으로 부담이 된다는 단점이 있다. 때문에 현재까지도 발파공법의 사용성이 큰 편이다.

발파공법은 화약류 등의 폭발력을 이용해 암반을 굴착하는 방법이다. 터널 발파공법 사용시, 주변 암반에 대한 손상을 최소로 하며 동시에 최적의 발파 효과를 얻을 수 있다. 다만 발파공법의 특성상 발파로 인한 소음과 진동이 발생하며 이는 주변환경에 영향을 미치게 되므로 시공시 이를 고려해야 한다. 발파작업시 발생하는 2차적 재해인 발파공해의 대부분의 피해는 발파 진동에 의해 나타난다(이광재, 2008). 때문에 최근에는 주거지 주변 현장에서는 민원발생을 최소화하고 굴착공사를 원활하게 수행할 수 있도록 일반발파보다 소음진동을 억제할 수 있는 굴착공법을 적용하는 공사 현장이 점차 증가하고 있는 추세이다.(터널및지하공간학회, 2016)

표 1 발파공법의 종류

구분	일반발파	진동제어발파	정밀진동 제어발파	미진동 굴착공법
공법개요	1공당 최대장약량이 발파규제기준을 충족시킬 수 있을 만큼 보안물건과 이격된 영역에 대해 적용하는 공법	발파영향권 내에 보안물건이 존재하는 경우 “시험발파” 결과에 의해 발파설계를 실시하여 규제기준을 준수할 수 있는 공법	소량의 폭약으로 암반에 균열을 발생시킨 후, 대형브레이커 에 의한 2차 파쇄를 실시하는 공법	보안물건 주변에서 정밀진동 제어발파이내 수준으로 진동을 저감시킬 수 있는 공법으로서 대형 브레이커로 2차 파쇄를 실시하는 공법
지발당장 약량(kg)	5.0~15.0	0.5~5.0	0.125~0.5	폭약기준 0.125 미만

\* 천공깊이, 최소저항선, 천공간격 치수 등은 평균적으로 제시한 수치이며, 공사시행 전에는 시험발파에 따라 현장별로 검토, 적용하여야 함

발파공법은 터널이 굴착되는 현장의 특성과 주변 환경의 영향등을 고려하여 진행되므로 제한조건이 발생한다. 이 중 심발발파는 터널 굴착시 가장 먼저 기폭되어 자유면을 형성하는 역할을 하는 것으로, 굴진효율과 발파의 진동, 소음 발생에 중요한 영향을 끼친다.

구 분	개요도	특징 및 장점
V-CUT		<ul style="list-style-type: none"> <li>천공폐편이 단순</li> <li>단공발파나 연암발파에서 효율적</li> <li>암죽 및 전단파괴, 대청원 경사공으로 폐기파괴</li> </ul>
Cylinder-CUT		<ul style="list-style-type: none"> <li>암죽 및 전단파괴, 대구경 무장약공을 자유면으로 활용</li> <li>굴진장 중대 가능</li> <li>심발부 진동 제어 가능</li> <li>장공발파나 경암발파에 이용됨</li> </ul>
SUPERX-CUT (신기술 제14호) (특허 제1199823)		<ul style="list-style-type: none"> <li>암죽 및 전단파괴, 천공 1차 발파후 수직공 2차 발파로 폐쇄</li> <li>비장약량이 적고 발파효율 좋음</li> <li>굴진자립이 개선되고 굴진시간이 줄어 경제적인</li> </ul>
COPA-CUT (신기술 제341호) (특허 제0443578호)		<ul style="list-style-type: none"> <li>인장파괴 및 암죽 및 전단파괴, Pre-splitting 효과 도입</li> <li>심발부 선균열로 발파진동 및 소음을 저감</li> <li>선균열로 발파효과 증대되며 천공수 감소</li> <li>선균열 발파로 비장약량이 작으며 굴착비가 저렴함</li> </ul>
다단평행발파 (특허 제0751729호)		<ul style="list-style-type: none"> <li>심발공을 단공과 장공으로 천공으로 저항선을 축소 단계별 발파</li> <li>저항선이 축소되어 발파효과가 증대되어 발파진동 소음이 저감됨</li> <li>천공수 증가로 화재위험 및 뇌관 사용량이 증가됨</li> <li>전자뇌관을 이용한 미진동 발파로 전환率이 용이함</li> </ul>
HTB-CUT (신기술 제459호)		<ul style="list-style-type: none"> <li>전단파괴에 의해 형성되는 자유면이 후방바닥을 자유면으로 폐쇄</li> <li>심발발파의 자유면이 완전하여 발파효율 증대</li> <li>발파진동 및 소음감소로 공해가 적게 발생</li> <li>V-CUT 발파폐편 이용하여 진동감소로 공해 최소화</li> </ul>

그림 1 Picture Explanation

## 2.2 선대구경 수평심발 공법

선대구경 수평심발 공법이란 굴착면 전방으로 10~60m정도 선진 보링한 직경 250 ~1,000mm의 대수경 수평보링공을 심발 발파시 무장약공으로 활용하는 터널 발파 공법이다. PLHBM(Pre Large Hole Horizontal Boring & Blasting Method)는 발파효율을 증대시킬 뿐만 아니라 경제성, 친환경성 까지 갖춘 발파공법이라고 할 수 있다(백종현 외, 2012). 또한 PLHBM은 다른 터널발파 심발공법인 V-cut에 비해 최소 21.8%에서 최대 61.1%에 달하는 진동 저감률을 보이는 것으로 선행 연구가 진행된 바 있다(최형빈 외, 2016).

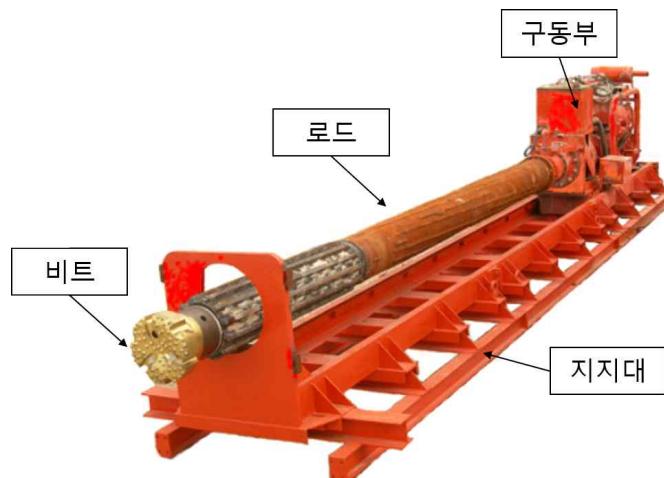


그림 2 선대구경 장비 상세 명칭(백종현 외)

## 2.3 지질 예측 방법

터널 발파 시 발생할 수 있는 여러 위험성들을 사전에 예방하고자 할 때 가장 중요한 것은 굴진면 전방의 지질 상태를 예측하는 것이다. 이때 탐사 방법에 따라 얻어지는 데이터들을 이용해 어느정도 지질 상태 예측이 가능하다는 결과가 여러 연구를 통해 도출된 바 있다.

천공시 유압 착암기에서 얻어지는 천공 데이터로부터 지반 특성과의 직접적인 연관성을 밝혀내고 더 나아가 시공효율까지 영향이 미친다는 점이 선행연구가 수행되었다. 천공시 얻어지는 천공데이터가 실제 대상이 되는 지반에서 얻어지는 직접적인 데이터이기 때문이다. 국내에서는 점보드릴의 유압착암기로부터 계측되는 회전압, 피드 압, 천공속도 등으로부터 전방 암반 특성을 평가하는 연구가 진행된 바 있다(김광염 외, 2009). 타 논문에서는 점보드릴의 천공 속도와 타격압 데이터를 이용해 암반의 강도를 예측할 수 있는 연구가 진행되었다(김광염 외, 2008). 특히 일본의 경우 천공 탐사시스템 구축을 위해 다양한 연구가 진행되었으며 이를 통한 상용화까지 마무리되어 실제 사용중에 있다(김광염 외, 2009) 이렇듯 천공데이터 분석에 대한 연구들은 굴진면 전방의 지질을 예측하고, 지반의 안정성을 파악하는 데 활용되고 있다.

다만, 국내의 천공데이터 연구에서는 현재 많이 사용되는 선대구경 장비를 활용해 전방 암반 상태를 예측하는 부분이 연구된 바 없다. 구체적인 시스템 구축을 위해서는 국내 현장에 맞는 천공데이터 분석 시스템 개발 및 연구가 선행되어야 하며, 또한 국내의 다양한 지반에 대한 데이터가 충분히 축적되어야 한다.

## 2.4 데이터 정규화

선대구경은 운전자가 조작해 굴착하기 때문에 Rotation, Feed에 이상치가 존재할 수 있다. 이 이상치들은 정확한 값이라기 보다는 운전자가 상황에 따라 굴착 시에 얻어진 일시적으로 발생한 값이기 때문에 정확한 수치가 아니다. 이렇게 발생한 이상치를 잘 처리해야 데이터를 가지고 학습을 시킬 때 더 정확한 결과를 얻을 수 있다.

데이터 간의 스케일(중요도)이 심하게 차이가 나는 경우 데이터 특성들의 차이로 인해 학습이 제대로 되지 않는 문제가 생길 수 있다. 데이터 간의 특성의 단위를 무시할 수 있도록 값의 범위를 일정하게 맞추어주는 것이 Scaling이다.

최적의 값에 도달하기 위한 비용함수를 줄여 더 빠르게 학습할 수 있게 된다. Local Optimum을 빠르게 빠져나갈 수 있게 되고 Global Optimum에 빠르게 도달하는 등 학습의 안정성 및 수렴속도를 향상시킨다.<sup>1)</sup>

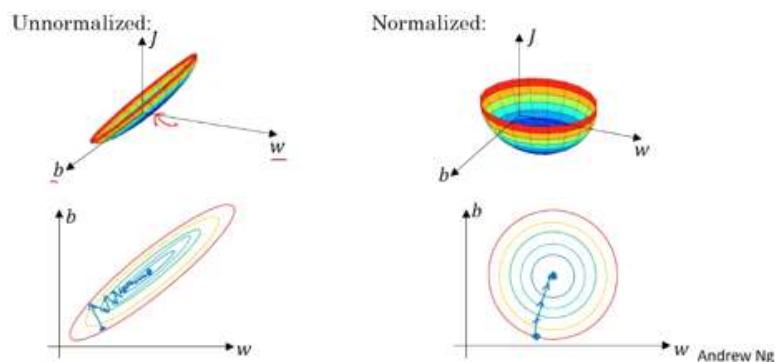


그림 3 Unnormalized와 Normalized일 때 차이  
(Andrew Ng, “Deep Learning AI”)

[그림3]에서 확인할 수 있듯이 정규화를 거치지 않은 경우 데이터들 간의 스케일의 차이가 발생해 학습이 빠르게 되지 않고 정규화를 거치면 그 스케일의 차이가 고르게 페져있어 더 적은 학습으로도 더 정확한 결과를 얻을 수 있음을 알 수 있다.

---

1) Impact of Data Normalization on Deep Neural Network for Time Series Forecasting, Samit et al.  
<https://arxiv.org/abs/1812.05519>

#### 2.4.1 Min-Max Normalization

Min-Max Normalization(최대-최소 정규화)은 모든 특성에 대해 최소값을 0, 최대값을 1로 두고 그 사이 구간의 값으로 변환하는 것이다.

$$x_{scaled} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

( $x_{\min}$ : 최솟값,  $x_{\max}$ : 최댓값,  $x$ : 입력 데이터)

최소-최대 정규화는 이상치(outlier)에 너무 많은 영향을 받는다는 단점이 있다. 극단적인 데이터들에 의해 최대 또는 최소값이 크게 변해 전체를 잘 반영하지 못한다. 이상치가 있는 경우 정규화된 데이터들의 범위가 좁은 범위로 압축될 수 있다.

#### 2.4.2 Standardization Normalization

평균과 표준편차를 사용하여 정규화하는 방식이다. 평균을 제거하고 데이터를 분산 단위로 조정한다.

$$x_{scaled} = \frac{x - m}{\sigma}$$

( $m$ : 평균,  $\sigma$ : 표준편차,  $x$ : 입력 데이터)

이 정규화 방식도 이상치가 있으면 평균과 표준편차에 크게 영향을 끼쳐 정규화된 데이터가 크게 달라지게 된다.

### 2.4.3 Robust Normalization

Robust Normalization은 아웃라이어의 영향을 최소화한 기법이다. 중앙값과 사분위값 IQR(Inter-Quartile Range)을 사용하여 정규화하는 방식이다.  $IQR = Q3 - Q1$ 로 75와 25 퍼센타일의 차이이다.<sup>2)</sup>

$$x_{scaled} = \frac{x - x_{2/4}}{x_{3/4} - x_{1/4}}$$

( $x_{3/4}$ : Q3,  $x_{2/4}$ : 중앙값,  $x_{1/4}$ : Q1,  $x$ : 입력 데이터)

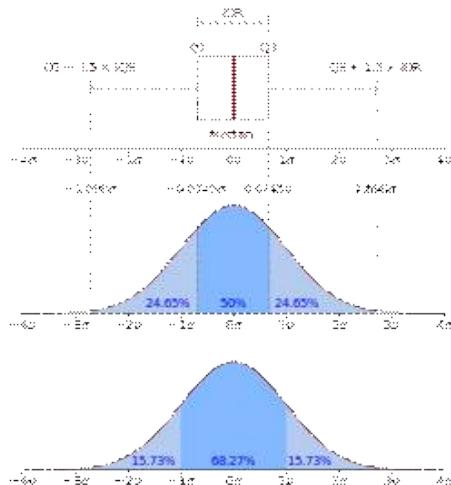


그림 4 Robust Normalization  
([https://en.wikipedia.org/wiki/Interquartile\\_range](https://en.wikipedia.org/wiki/Interquartile_range))

정규화는 이상치를 제거하지는 못하고 데이터 간의 스케일을 동일하게 조정하는 역할을 하는 것이기 때문에 정규화 전에는 이상치를 먼저 제거하는 것이 필요하다. 그리고 데이터의 특성에 맞게 알맞은 정규화를 진행하는 것이 좋다.

2) [https://en.wikipedia.org/wiki/Interquartile\\_range](https://en.wikipedia.org/wiki/Interquartile_range)

## 2.5 활성함수 (Activation Function)

뉴런이 다음 뉴런으로 신호를 보낼 때 입력신호가 일정 기준 이상이면 신호를 보내고 기준에 미치지 못하면 보내지 않는다. 이 원리를 적용하기 위해 신호를 보낼지 결정해 주는 것이 활성함수 (Activation Function)이다. 많은 종류의 활성함수가 있고 활성함수에 따라 결과가 크게 변하게 된다.

### (1) Sigmoid 함수

Sigmoid는 비선형함수로  $\sigma(x) = \frac{1}{1 + e^{-x}}$ 이고 미분값은  $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ 이다.

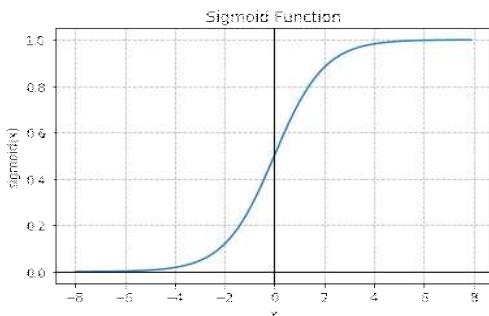


그림 5 Sigmoid Function

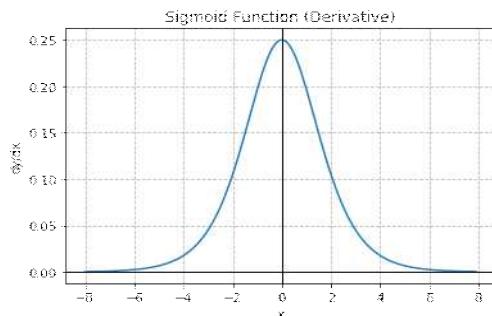


그림 6 Derivative Sigmoid Function

Sigmoid는 함수값이 (0,1)로 제한되고 중간값은 0.5이다. 매우 큰 값을 가지면 함수값은 1에 수렴하고 매우 작은 값을 가지면 0에 수렴하는 특징을 가진다.

하지만 sigmoid는 Gradient Vanishing 현상이 발생한다. 미분함수에 대해  $x = 0$ 에서 최대값 0.25를 가지고,  $x$ 값이 일정 이상 올라가면 거의 0에 수렴하게 된다. 이는  $|x|$ 값이 커질수록 Gradient Backpropagation시 미분값이 소실될 가능성이 크다. 그리고 원점 중심이 아니다 (Not zero-centered). 따라서 평균이 0이 아니라 0.5이며 sigmoid 함수는 항상 양을 출력하기 때문에 출력의 가중치 합이 입력의 가중치 합보다 커질 가능성이 높다. 이것을 편향 이동(bias shift)라고 하며, 이러한 이유로 각 레이어를 지날 때마다 분산이 계속 커져 가장 높은 레이어에서는 활성화 함수를 출력이 0이나 1로 수렴하게 되어 그래디언트 소실 문제가 일어나게 된다.

## (2) Hyperbolic Tangent 함수

원점중심이 아닌 문제를 해결한 활성함수가 Hypoerabolic Tangent이다.

Hypoerabolic Tangent는  $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$  이고 미분값은  $\tanh'(x) = 1 - \tanh^2(x)$  이다.

함수의 중심값을 0으로 옮겨 sigmoid의 쇠적화 과정이 느려지는 문제를 해결하였다. 하지만 미분함수에 대해 일정값 이상 커질 시 미분값이 소실되는 Gradient Vanishing 문제는 여전히 남아있다.

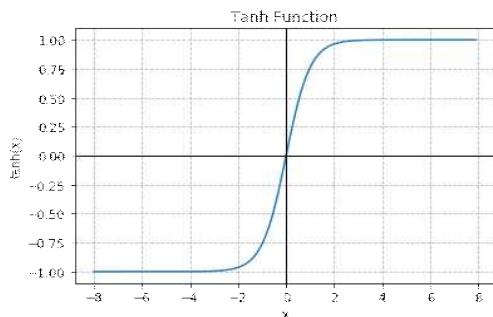


그림 7 Hyperbolic Tangent

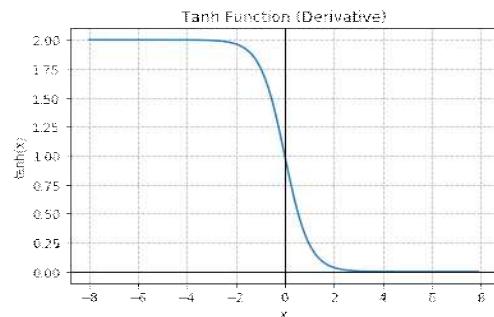


그림 8 Derivative Hyperbolic Tangent

## (3) ReLU 함수

ReLU(Rectified Linear Unit) 함수는  $f(x) = \max(0, x)$  이다.  $x > 0$  이면 기울기가 1인 직선이고  $x < 0$  이면 함수값이 0이 된다. 구현이 간단하기 때문에 연산비용이 크지 않기 때문에 계산 속도가 빠르다. Sigmoid와 Tanh에 비해 SGD(Stochastic Gradient Descent)에서 수렴속도가 무려 6배나 빠르다.<sup>3)</sup> 하지만  $x < 0$  구간에서 함수값이 0이기 때문에 뉴런이 죽을 수 있는 단점이 존재한다.

## (4) Leaky ReLU 함수

Leaky ReLU는 ReLU 함수에서 뉴런이 죽는 현상을 해결하였다. 함수도 매우 간단한 형태로  $f(x) = \max(0.01x, x)$  이다.  $x < 0$  구간에서도 함수값이 매우 작은 값으로 존재하기 때문에 음수에서도 미분값이 0이 되지 않는다.

3) <http://www.cs.toronto.edu/~fritz/absps/imagenet.pdf>

ImageNet Classification with Deep Convolutional Neural Networks. Krizhevsky et al.

## (5) ELU 함수

ELU(Exponential Linear Unit)<sup>4)</sup>는  $x < 0$ 일 때 활성화 함수값이 평균이 0에 가까워지기 때문에 편향 이동(bias shift)이 감소하여 그래디언트 소실 문제를 줄여준다.  $x < 0$ 이어도 값이 0이 아니므로 뉴런이 죽는 문제가 없다. 그리고  $\alpha = 1$ 일 때 ELU는  $x = 0$ 에서 급격하게 변하지 않고 모든 구간에서 매끄럽게 변하기 때문에 경사하강법에서 수렴속도가 빠르다.

$$ELU_{\alpha} = \begin{cases} \alpha(\exp(x) - 1) & \text{if } x < 0 \\ x & \text{if } x \geq 0 \end{cases}$$

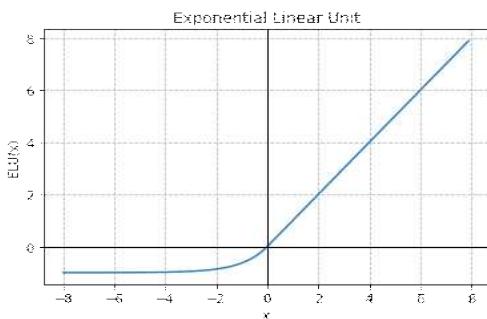


그림 9 Exponential Linear Unit

어떤 활성함수를 사용하느냐에 따라 노드가 활성화될지 안 될지를 결정하기 때문에 사용할 활성함수를 학습 방법과 상황에 맞게 적절하게 잘 선택하는 것이 예측 결과에 큰 영향을 미친다. 특히 Gradient Vanishing 문제가 발생하는지, 노드가 죽는 문제가 발생하지 않도록 유의하며 학습해야 한다.

---

4) <https://arxiv.org/pdf/1511.07289.pdf>

FAST AND ACCURATE DEEP NETWORK LEARNING BY EXPONENTIAL LINEAR UNITS (ELUS)  
B.Xu et al.

## 2.6 인공지능

선대구경 굴착 과정 중 PLHBM 장비에서 얻은 데이터와 천공 내부 이미지를 통해 얻은 암등급 데이터를 활용하여 암등급을 예측하는 인공지능 모델을 만든다. 이렇게 만들어진 인공지능 모델을 활용하여 PLHBM 장비에서 추출한 데이터만 있으면 암등급을 정확도 있게 예측할 수 있다.

선대구경이 굴착하며 나아가는 과정에서 얻어지는 데이터는 시계열 데이터이다. 시계열 데이터를 학습하는 데에는 RNN(Recurrent Neural Network)이 많이 사용되었다. 그리고 최근에는 RNN의 문제를 개선한 LSTM(Long Short-Term Memory model)을 많이 사용하고 있다. LSTM을 활용하여 이 연구를 진행하였다.

### RNN과 LSTM

RNN(Recurrent Neural Network)은 일련의 연속성이 있는 생각을 잘 하지 못한다는 기존의 Neural Network 문제를 해결하기 위한 모델이다. RNN은 이전 단계에서 정보를 고려하도록 한다.

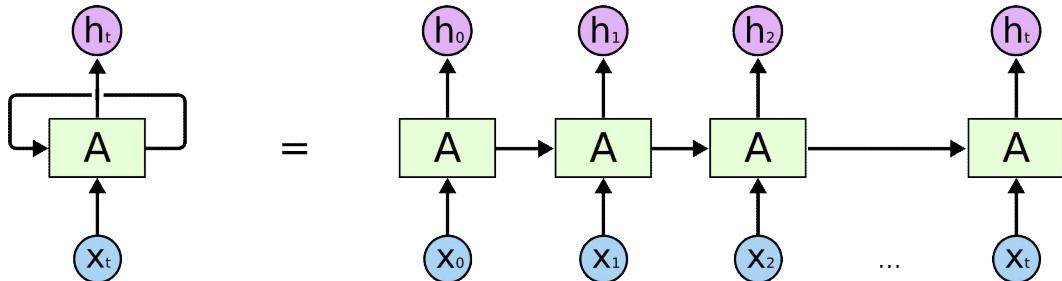


그림 10 Recurrent Neural Network

RNN은 입력으로 받은 데이터를 순전파(Forward Propagation)하여 이를 다음 모델에 함께 이용하는 구조로 되어있다. 이렇게 RNN의 체인처럼 이어지는 구조의 네트워크는 연속적인 데이터를 잘 다루는 역할을 하게 되어있다. RNN은 실제로 음성 인식, 번역, 이미지 추석 생성 등에서 성공적으로 사용되고 있다.

RNN은 긴 의존 기간에 대한 문제점을 가지고 있다. 필요한 정보를 얻기 위한 시간 격차가 크지 않다면, RNN도 지난 정보를 바탕으로 학습할 수 있다. 하지만 더 긴 문 맥을 필요로 하는 경우처럼 긴 의존 기간을 필요로 하는 경우 RNN은 좋지 못한 결과를 보여준다

LSTM은 긴 의존 기간을 필요로 하는 학습을 수행할 능력을 갖고 있다. RNN과 LSTM 모듈은 아래와 같이 구성되어 있다.

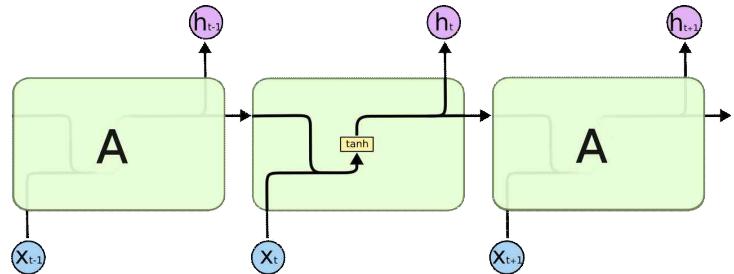


그림 11 RNN 구조

모든 RNN은 neural network 모듈을 반복시키는 체인과 같은 형태를 하고 있다. 기본적인 RNN에서 이렇게 반복되는 모듈은 굉장히 단순한 구조를 가지고 있다.

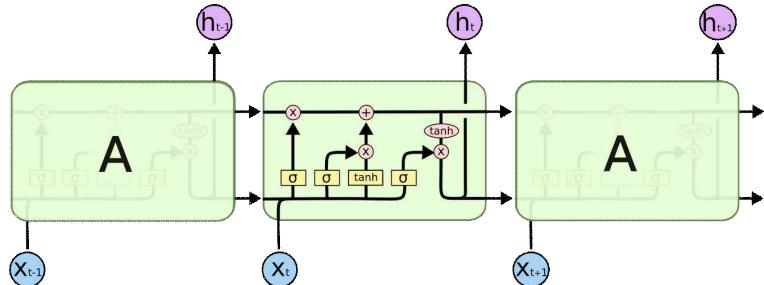


그림 12 LSTM 구조

LSTM도 똑같이 체인과 같은 구조를 가지고 있지만, 각 반복 모듈은 다른 구조를 갖고 있다. 단순한 neural network layer 한 층 대신에, 4개의 layer가 특별한 방식으로 서로 정보를 주고 받도록 되어 있다.<sup>5)</sup>

5) Long Short-Term Memory (LSTM) , Sepp et al.

<https://www.bioinf.jku.at/publications/older/2604.pdf>

<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

<https://dgkim5360.tistory.com/entry/understanding-long-short-term-memory-lstm-kr>

## 제3장 현장조사 및 데이터 수집

### 3.1 현장소개

영덕군 강구면 화전리의 소하천에서는 매년 수해가 되풀이되고 있다. 2018년의 태풍 ‘콩레이’, 2019년의 태풍 ‘미탁’에 이어 작년 2020년도에도 집중호우로 인해 또다시 저지대가 침수되는 사고가 발생했다. 지난 2018년에는 태풍 콩레이로 영덕에 최고 383mm의 집중호우가 내려 1명이 숨지고 주택 1천15채가 물에 잠겼다. 매 해 침수가 발생하는 지역이기 때문에 배수펌프가 설치되어 있음에도 불구하고 실제 응급 상황에서 제 역할을 다하지 않았던 것으로 밝혀졌다.(손대성, ‘3년 연속 침수 피해 영덕 강구면’, 2020.07.24.)

때문에 본 현장에서는 범람에 대한 대책으로 소하천에서 바다로 물을 흘려보낼 수 있는 배수로 작업이 진행중이다. 공사를 위해 인근 주민들을 대상으로 설명회를 개최하여 사업추진 상황을 설명하고 궁금한 점에 대한 질의응답을 진행하였다.(박승배, ‘강구화전소하천 재해복구사업 마무리공사 박차’, 2020.11.18) 소하천 정비 공사는 길이 736m, 폭 5.4m, 높이 4.6m로 터널 관통 후 터널 내부 바닥 콘크리트 및 벽체 라이닝, 유입수로등의 작업이 상당수 진행되었다.(이승형, ‘영덕 강구 매년 물난리 나는데 더디 기만 한 재해복구’, 2020.07.24.)



그림 13 현장 정면 모습

### 3.2 데이터 수집 및 소개

본 연구는 선대구경을 이용한 발파 작업시 획득한 천공데이터를 이용해 전방 암반 상태를 예측하고자 했다. 여기서 필요한 주요 천공데이터는 회전압, 추진압, 천공 속도이다. 그러므로 이를 위해 실제 현장의 천공데이터와 이에 걸맞는 암반특성 데이터를 수집하였다. 그림을 참고하면, 위에서부터 회전압, 추진압, 속도(천공거리로 계산해 냈다.) 데이터이다.

회전압과 추진압 데이터를 획득하기 위해 선대구경 장비에 유압 센서를 부착해 사용하였다. 천공거리 데이터를 수집하기 위해서는 와이어 센서를 사용하였다. 또한 output 데이터를 위한 암반특성 데이터 수집을 위해 천공 훌 내부를 촬영할 수 있는 장비를 사용하였다. 또한 선대구경 장비 특성상 5m 천공이 끝날때마다 새로운 로드를 끼워야 하기 때문에 5m 간격으로 천공데이터에 오차가 발생한다. 때문에 전처리과정을 통해 이러한 오차를 최대한 줄일 수 있도록 했다.

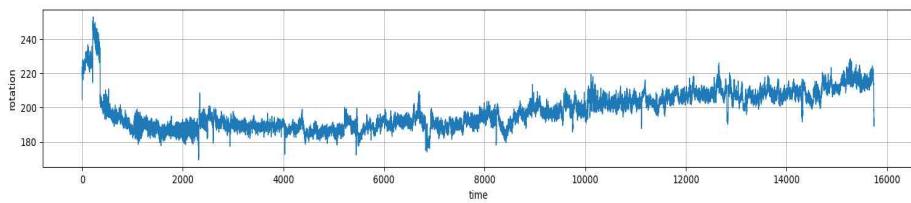


그림 14 회전압 데이터

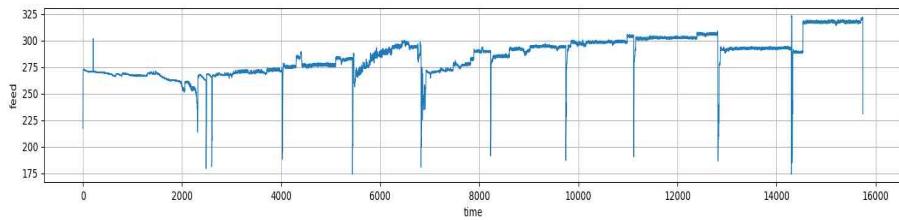


그림 15 추진압 데이터

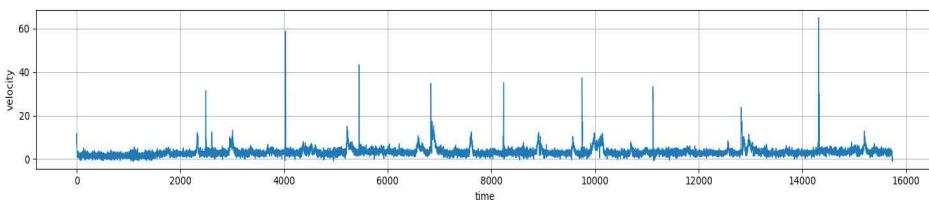


그림 16 천공 속도 데이터

### 3.2.1 회전압 및 추진압 데이터

회전압 및 추진압 데이터를 수집하기 위해 선대구경 장비에 유압 센서를 부착해 사용하였다. 사용한 유압센서의 제원은 표 3과 같다. 센서는 선대구경 장비의 유압을 조절하는 컨트롤 레버가 있는 위치에 부착하여 사용하였다. 또한 선대구경의 유압 호스나사 규격과 일치하고, 천공 작업시 안전하게 사용할 수 있도록 0~350bar 의 압력이 측정 가능한 장비를 사용하였다.

표 2 유압센서 제원

구분	제원
모델명/제조사	M54 / Sensys
압력부 나사규격	R(PT) 1/4
측정 압력 범위	0~200 bar, 0~350 bar, 0~700 bar
정밀도	0.1 bar

### 3.2.2 천공거리 데이터

천공거리 데이터를 수집하기 위해 실시간으로 측정이 가능한 와이어 센서를 사용하였다. 해당 센서의 제원은 표 4와 같다. 와이어 센서 특성상 움직이는 대상에 금속 와이어를 걸어 이동 정도를 측정하기 때문에 천공작업에 노출되어 센서가 손상될 가능성이 있었다. 때문에 이를 예방하기 위해 지지대 하부 유압 실린더가 있는 위치에 와이어센서를 설치해 사용하였다. 유압실린더는 변위가 구동부의 절반 정도 발생하며 3.5m 이상 움직이지 않는 도르래와 같은 구조를 가지는 특징이 있다.

표 3 와이어 센서 제원

구분	제원
모델명	CMM-5000
제조사	COZY Inc.
측정 범위	0~5000 mm
정밀도	0.01 mm

### 3.2.3 암반특성 데이터

암반특성 데이터는 선대구경 장비로 만들어낸 천공 내부로 촬영장치를 진입시켜 얻어낸 영상데이터로 획득했다. 이를 위해 사용한 해당 장비의 제원은 표 5과 같다. 해당 장비를 사용하여 천공홀 내부의 영상을 360°로 촬영이 가능하였으며, 연속적인 촬영으로 인해 특정 지점에 대한 자세한 관찰이 가능하였다.

**표 4** 암반특성 데이터 계측장비 제원

구분	제원
길이(Length)	480mm
운용 직경(Diameter)	350~400mm
이동가능 거리	0~70m
카메라 모델	Insta 360 ONE X
조명 사양	10~135 루펜 * 4ea
무게	약 11kg
방수성능	수심 1m 완전방수 가능

해당 장비를 통해 촬영된 영상을 통해 굴진면의 불연속면의 존재와 개수를 직접 확인하여 거리당 암반의 등급을 자체적으로 매겼으며 추후 이를 숫자로 환산하였다. 이를 통해 암반특성데이터를 확보하였는데, 이 과정에서 RMR, RQD 등 암질을 수치화 할 수 있는 다양한 기준을 사용했다. RMR은 암석의 일축압축강도(UCS, Uniaxial compressive strength), 암질지수(RQD, Rock quality designation), 불연속면 간격, 물연속면 상태, 지하수 상태, 불연속면의 방향 등을 고려하여 터널 굴착면의 상태를 수치화한 것이다.(김해만 외, 2019) 해당 기준들을 사용해 1m 간격으로 암반 등급에 대한 구분을 진행했다. 불연속면의 개수가 1개 이하 존재한다면 1등급으로, 불연속면의 개수가 2개이상 4~5개 미만이라면 2등급으로 측정하였다. 불연속면의 개수가 6개 이상이거나 확실한 절리가 여러개 존재한다면 3등급으로, 물이 흐른 흔적이 있거나 깊은 절리로 인해 파인 흔적이 보이고 불연속면의 존재와 개수가 확실히 많다면 4등급으로 측정하였다. 또한 등급간 값은 최대 15로 최소 0으로 설정하여 그래프화 하여 가독성을 높였다. 이와 같은 사안들을 정리해서 표 4에 정리하였다. 또한 천공이 진행된 50m 전체 구간에 대한 평가는 그래프화 하여 [그림 12]에 첨부하였다.

표 5 암반특성 데이터 판단 기준

등급	점수	판단 기준
1등급	15	불연속면의 개수가 1개 이하이다.
2등급		불연속면의 개수가 2개 이상 4~5개 미만이다.
3등급	0	불연속면의 개수가 6개 이상이다 절리가 존재한다.
4등급		불연속면의 존재가 확실하며, 개수가 매우 많다. 절리로 인해 깊이 파인 흔적이 있다. 물이 흐른 흔적이 있다.

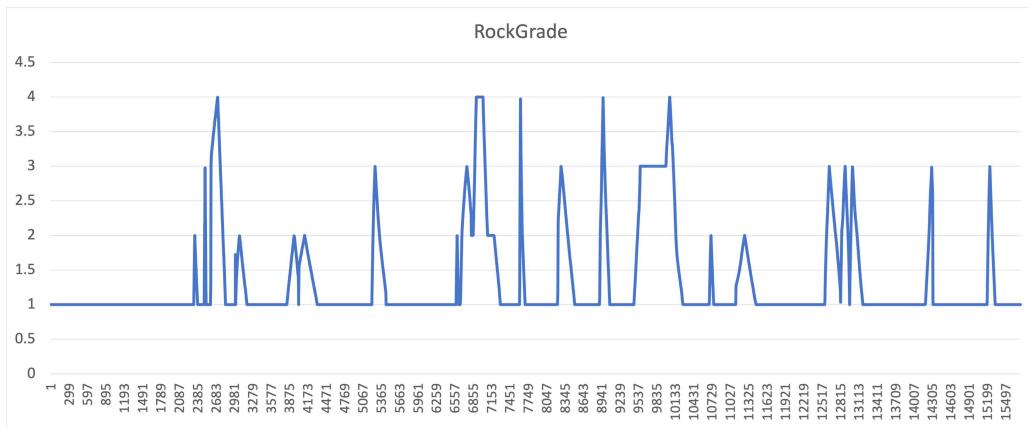


그림 17 암등급(Rock Grade)

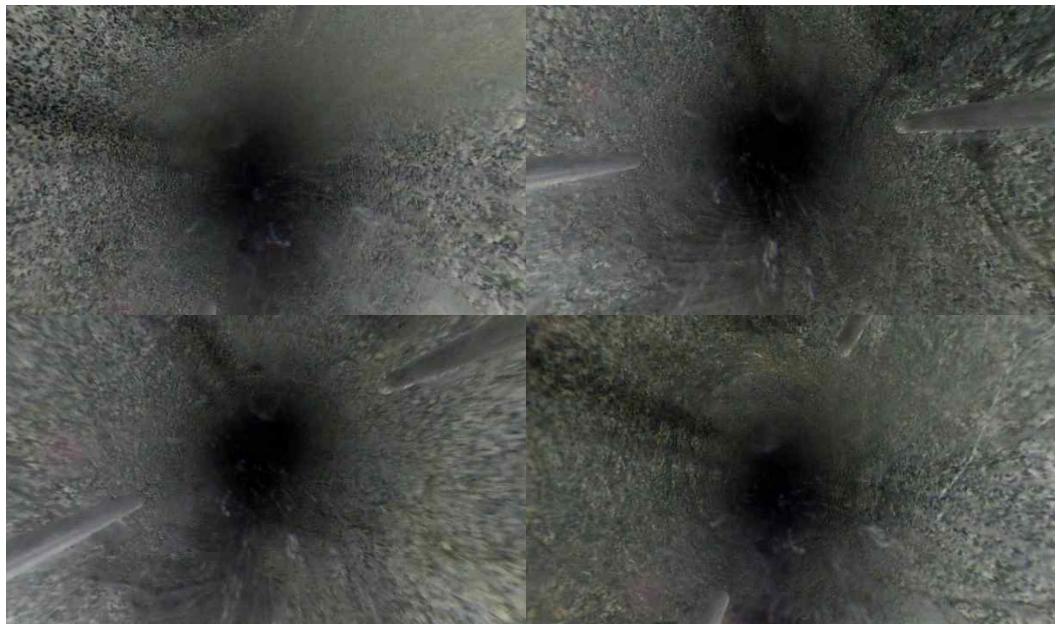


그림 18 높은 등급의 암반

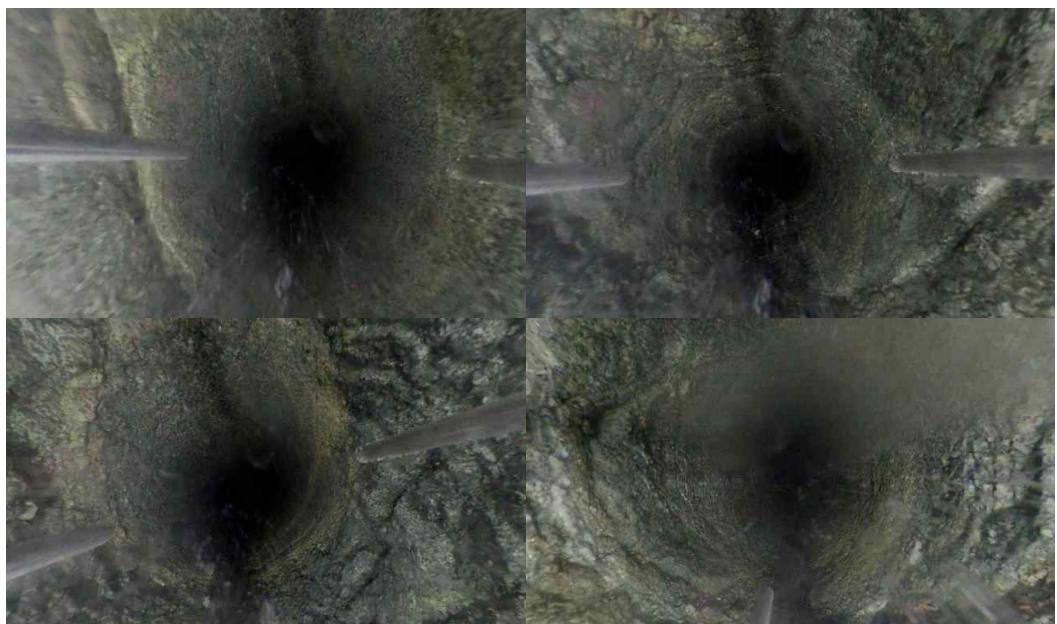


그림 19 낮은 등급의 암반

### 3.3 데이터 전처리

PLHBM 장비 앞에 카메라를 부착해 터널 내부 50m의 이미지 정보를 얻었다. 카메라를 통해 얻은 이미지를 통해 라벨링한 암석의 등급과 PLHBM의 위치 데이터(p1)를 기록한다. 그리고 PLHBM 장비의 실린더의 움직임을 통해 계산한 위치(p2), 회전압, 피드압, 속도 데이터를 얻었다.

PLHBM의 위치 데이터(p1)와 실린더의 위치(p2)를 매핑하여 최종 데이터를 산출하였다. 그래서 위치에 따른 회전압, 피드압, 속도(x)와 해당 위치의 암등급(y)을 도출해 냈다.

PLHBM의 각 위치(p1)를 실린더의 위치 스케일로 변환한 뒤 실린더의 위치(p2)를 p1의 맞는 구간을 찾아서 매핑시켰다. 매핑할 때 정확한 위치가 없는 경우에는 p1의 인접한 구간을 선형 보간법을 사용하여 계산하였다.

향후 연구에서도 같거나 비슷한 방식의 전처리가 이루어질 것을 예상하여 선형 보간법의 방법과 3가지 정규화 방식(Min-Max Normalization, Standardization Normalization, Robust Normalization)을 코드로 구현해 빠른 전처리에 도움이 되도록 하였다. 선형 보간법의 경우에는 두 위치 (p1과 p2)를 하나씩 비교하는 과정이 많은 노력과 시간이 드는 과정이다. 파이썬 클래스 코드(RockGrader)로 구현하여 향후 연구에도 많은 도움이 될 것으로 예상한다. 이 연구의 모든 코드는 github의 nobel6018/PHLBM\_LSTM 레포지토리에서 확인할 수 있다.

이렇게 얻은 데이터에는 이상치들이 존재한다. 선대구경 굴착은 운전자에 의존하기 때문에 큰 흐름은 비슷하지만 운전자마다 다를 수 있는 데이터이고 사람이 운전하다 보니 발생할 수 밖에 없는 이상치들이 존재한다. 그래서 이상치를 잘 처리하여 입력 데이터로 사용하였다.

### 3.4 상관분석

수집한 데이터들의 상관관계를 분석해 암등급에 가장 큰 영향을 미치는 영향도를 확인하고 분석 모델을 예측 및 확정 짓기 위함이다. 암등급과 회전압, 피드압, 속도와의 상관관계를 확인해보았다.

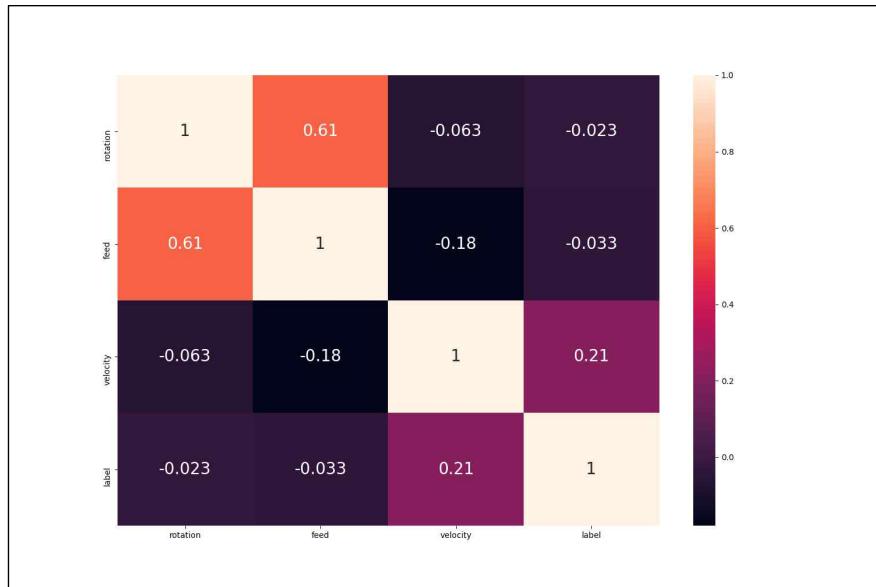


그림 20 회전압, 피드압, 속도 간의 Correlation Coefficient

암등급과 회전압, 피드압, 속도와의 상관계수는 각각  $-0.023$ ,  $-0.033$ ,  $0.21$ 로 회전압과 피드압은 음의 상관관계를 가지고 속도는  $0.21$ 로 양의 상관관계를 가지며 가장 연관관계를 가짐을 확인할 수 있다.

이 연구에서는 회전압, 피드압, 속도 3개의 데이터를 입력 값으로 사용하여 암등급을 예측하는 모델을 만들어볼 것이다.

## 제4장 LSTM 알고리즘 학습

### 4.1 학습 계획

천공시에 측정된 회전압, 피드압, 타격압, 천공속도 등의 천공 데이터를 LSTM(Long Short-Term Memory model)을 이용하여 암석의 등급을 예측해본다. 장비에서 얻어진 이미지, 계측 수치를 학습에 맞는 데이터로 가공한 뒤에 데이터 정규화 과정을 거친다. 그 후 Tensorflow Engine의 Keras로 LSTM으로 학습한다. 이 때 파라미터와 레이어를 추가하거나 변경시켜 최적의 결과를 내는 모델을 구해본다.

### 4.2 데이터 가공

PLHBM 장비 앞에 카메라를 부착해 터널 내부 50m의 이미지 정보를 얻을 수 있다. 카메라를 통해 얻은 이미지를 통해 라벨링한 암석의 등급과 PLHBM의 위치 데이터(p1)를 기록한다.

그리고 PLHBM 장비의 실린더의 움직임을 통해 계산한 위치(p2), 회전압, 피드압, 속도 데이터를 정리한다. PLHBM의 위치 데이터(p1)와 실린더의 위치(p2)를 매핑하여 최종 데이터를 얻었다. 위치에 따른 회전압, 피드압, 속도(x)와 해당 위치의 암등급(y)을 도출해냈다.

PLHBM의 각 위치(p1)를 실린더의 위치 스케일로 변환한 뒤 실린더의 위치(p2)를 p1의 맞는 구간을 찾아서 매핑시켰다. 매핑할 때 정확한 위치가 없는 경우에는 p1의 인접한 구간을 선형 보간법을 사용하여 계산하였다.

PLHBM의 위치 데이터(p1)을 기록할 때 카메라의 이동거리와 시간을 기록한 정보를 사용한다. 장비 앞에 카메라를 부착해 앞으로 이동할 때 와이어 길이의 제약으로 끝까지 이동한 후 카메라를 꺼내고 길이를 더 늘린 후 다시 앞으로 이동을 반복한다.

이를 그래프로 그렸을 때 [그림21]과 같은 그래프로 표현된다. 우리가 원하는 데이터는 카메라가 계속 앞으로 이동했을 때 그 위치와 그 위치에서의 암등급이다. 그래서 데이터를 가공하여 와이어가 계속 앞으로 이동했을 때의 데이터로 가공했다.

와이어를 뒤로 다시 이동시키는 구간을 제거하고 와이어의 이전 최종 위치를 다음에 시작한 와이어의 시작 위치와 일치시켜 데이터를 가공해 와이어에 이어진 카메라가 계속 앞으로 전진했을 때의 시간과 와이어 위치 데이터로 가공하였다.

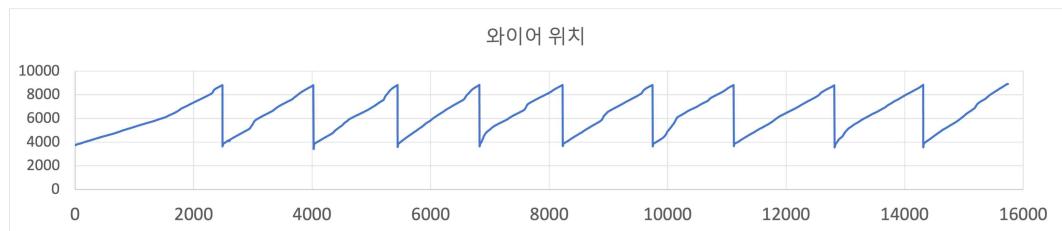


그림 21 PLHBM의 원본 위치 데이터



그림 22 PLHBM의 가공된 위치 데이터

카메라가 계속 앞으로 전진했을 때의 상황에서의 데이터에서 카메라의 이동속도를 구하였다. [그림 22]은 카메라가 계속 앞으로 이동했을 때의 상황에서 얻어진 속도 데이터이다. 여기서 얻어진 카메라의 이동속도에는 이상치(Outlier)가 많음을 확인할 수 있다. 현장에서 작업할 때 와이어의 이동속도가 일정하지 않고 특히 와이어의 최대 길이에서 카메라를 뺄 때나 와이어를 처음 넣기 시작하는 구간에서 더욱 그런 경향이 커졌다.

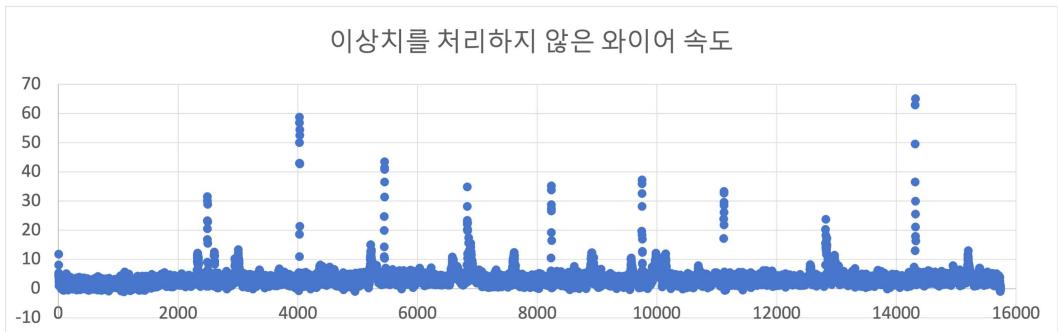


그림 23 와이어의 속도

그래서 이 이상치를 먼저 줄이기 위해 와이어 속도를 가공하였다. 이상치가 너무 많으면 학습이 이상치에 영향을 너무 많이 받아 정확한 결과를 얻기 힘들고 이상치에 의존하는 결과가 나올 수 있다. 데이터 정규화 과정에서 Robust Normalization과 같은 방법으로 이상치를 어느 정도 보정할 수 있기는 하지만 이상치가 너무 많이 있는 데이터는 그 자체가 데이터이기 때문에 정확한 보정이 어렵다. 그래서 원 데이터를 합리적인 수준으로 우선 보정하는 과정이 필요하다.

이 이상치 처리는 학습에 중요한 변수이기 때문에 이상치에 대한 방향 설정이 중요하다. 데이터에서 나온 이상치를 판별해보았을 때 와이어가 최대로 들어갔을 때를 기점으로 발생하였다고 판단했기 때문에 이 때 이상치는 적극적으로 처리하는 쪽으로 방향을 정해 처리하였다. 연구에서는 속도가 15(cm/s) 이상이면 이상치 데이터로 판단하였고 이 이상치 속도들에서 9를 뺀 다음 70% 속도를 줄여 이상치를 처리하였다.

$$v_{processed} = (v_{outlier} - 9) \times 0.3$$

( $v_{processed}$ : 이상치를 처리한 속도,  $v_{outlier}$ : 속도 이상치)

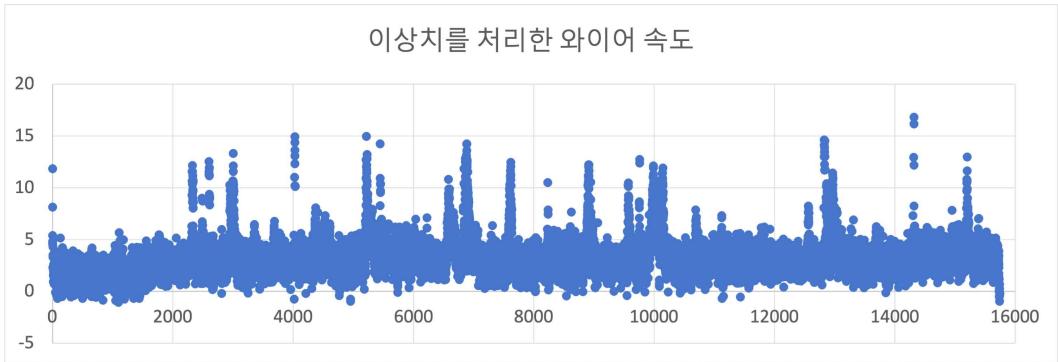


그림 24 이상치를 처리한 와이어의 속도

이상치를 처리한 와이어 속도의 결과는 [그림 24]와 같다. 이상치를 처리한 데이터를 살펴보면 평균적으로 0과 5사이에 많이 분포하고 이상치들은 대부분 15를 넘지 않는다. 그리고 와이어의 길이 한계점에서 덜 이상치가 발생함을 확인할 수 있다. 그리고 이상치를 처리하기 전 데이터와 이상치를 처리한 데이터를 비교해보면 15200번 째 구간, 3000번 째 구간, 6900번 째 구간과 10100번 째 구간 등에서 확인할 수 있듯이 기준에는 크게 나타나지 않았던 새로운 높은 값들을 확인할 수 있다. 이는 이상치의 데이터의 영향력이 줄어들고 기존 데이터의 이상치가 아니었던 높은 속도들이 더욱 상대적으로 더욱 크게 부각되었기 때문이다. 이상치를 적극적으로 처리한 결과는 학습에 유의미한 결과를 미칠 것으로 예상할 수 있다.

### 4.3 데이터 정규화

Min-Max Normalization, Standardization Normalization, Robust Normalization을 실행해보았다. 각 정규화 결과를 입력값으로 적용하여 예측 결과를 도출해보았다.

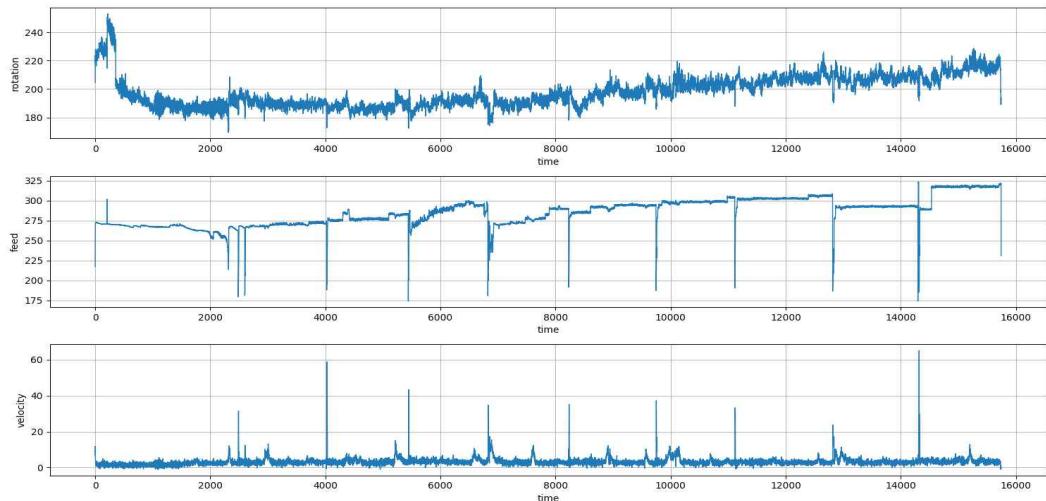


그림 25 정규화를 하지 않은 데이터

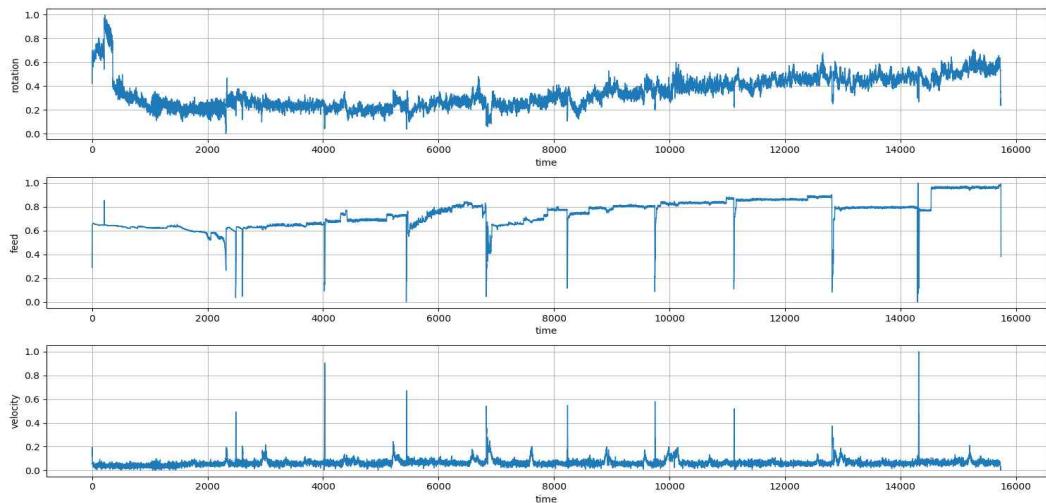


그림 26 Min-Max Normalization을 한 데이터

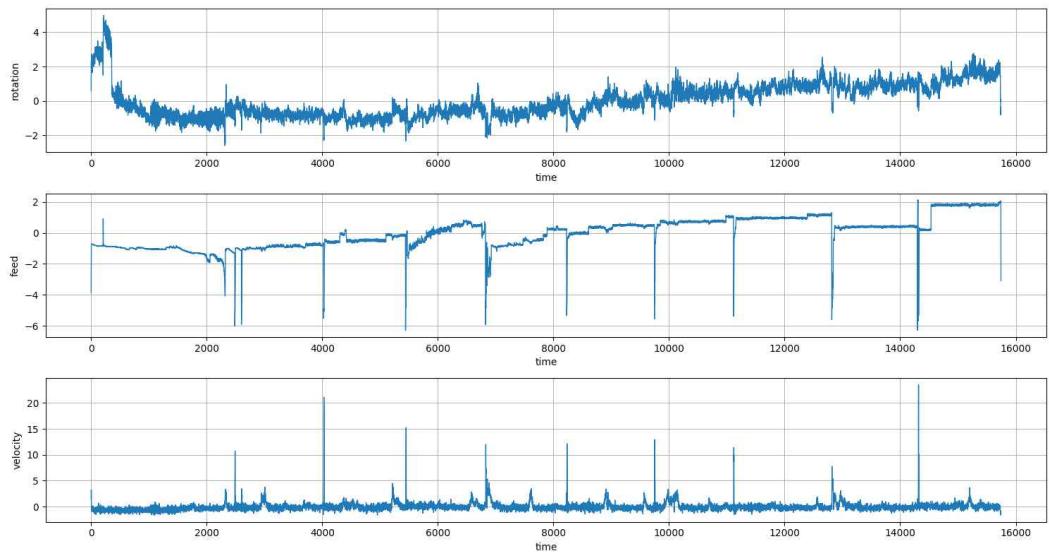


그림 27 Standardization Normalization을 한 데이터

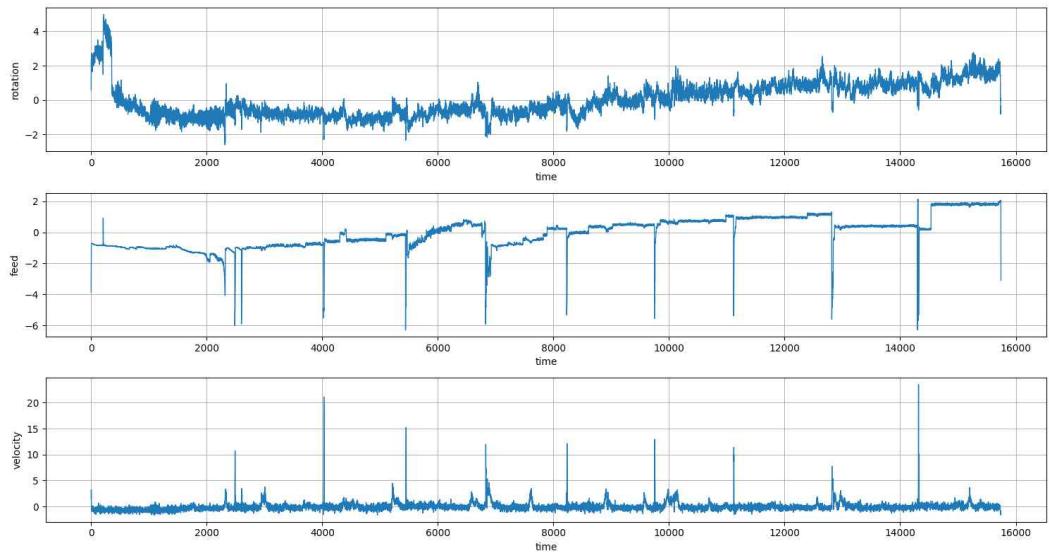


그림 28 Robust Normalization을 한 데이터

결과를 분석한 결과 모든 정규화 결과들의 데이터 개형은 비슷함을 알 수 있었다. 주의 깊게 확인해보았던 것은 각각 결과들의 스케일이다. 스케일 차이가 가장 커진 것은 정규화를 하지 않은 것의 데이터이다. Feed의 데이터 값들이 Velocity 데이터 값들보다 훨씬 크게 나타남을 알 수 있다. Standardization Normalization, Robust Normalization을 한 데이터는 Rotation과 Feed는  $-5 \sim +5$  사이에 분포하지만 Velocity 값의 범위들이 큰 것을 확인할 수 있다. 각각의 Normalization에 대해 정규화 결과에 대해서 예측 결과를 도출해보았다. 활성함수는 ReLU로 하였고 드롭아웃은 적용하지 않았다.

**표 6** 정규화 함수를 변경했을 때 각각의 Loss 결과

정규화 함수	Loss
Min-max Normalization	0.3752
Standardization Normalization	0.2306
Robust Normalization	0.2249

실제로 구해본 결과에서는 Robust Normalization이 가장 좋은 결과를 보여주었다. 데이터 간의 스케일을 가장 고르게 분포시킨 Min-Max Normalization이 가장 안 좋은 결과를 보여주었다. 우리 데이터에서는 Min-Max Normalization이 잘 처리했던 데이터들 간의 스케일 차이보다 Robust Normalization이 잘 처리하는 이상치 처리가 결과에 더욱 좋은 영향을 미쳤음을 알 수 있었다.

Min-Max Normalization 처리한 후 얻어진 예측 데이터에서는 예측들이 일정 구간에 간혀 예측하는 것처럼 보여졌다. [그림 26]에서 볼 수 있듯이 입력값들이  $0 \sim 1$ 의 값으로 만들어져 있기 때문에 결과도 같은 형태를 띠는 것으로 생각된다.

우리의 데이터에서는 이상치 처리를 잘하는 Robust Normalization이 가장 좋은 결과를 얻었다. Robust Normalization으로 처리한 입력 데이터는 [그림 28]에서 볼 수 있듯이 각각의 값들의 이상치를 처리하는 동시에 값들의 특징을 최대한 잘 살리며 결과를 도출해기 때문에 우리의 데이터에 더욱 잘 맞았음을 알 수 있다. 예측 결과를 보았을 때 Min-Max Normalization 예측 결과와 다르게 값들의 범위가 좀 더 넓고 디테일을 좀 더 잘 표현하는 모습으로 나타난다.

이 연구에서는 데이터 간의 스케일 차이가 중요하기보다는 이상치를 잘 처리하면서 값들의 특징을 잘 살리는 것이 더욱 중요하다고 판단해 Robust Normalization으로 데이터를 정규화하는 게 좋다고 결론을 내렸다.

## 4.4 파라미터 변경에 따른 학습 결과

약 1만 5천개의 데이터로 너무 많은 학습을 시키면 과적합(Overfitting) 문제가 발생할 수 있기 때문에 단일 레이어에 시작하여 활성함수(Acivation Function)와 드롭아웃(Droupout)을 변경하며 각각의 모델로 예측 결과를 확인해보았다.

### 4.4.1 활성함수(Acivation Function)를 변경했을 때의 학습 결과

활성함수들의 각기 다른 특성들로 인해 연구에서는 sigmoid, tanh, ReLU, Leaky ReLU, ELU로 변경해가며 테스트 해 보았다. 각각의 결과는 [표 8]과 같았다.

표 7 활성함수를 변경했을 때 각각의 Loss 결과

활성함수	Loss
tanh	0.3943
Sigmoid	0.5635
ReLU	<b>0.3752</b>
LeakyReLU	0.3922
ELU	0.3872

LSTM은 기존 결과값을 다시 입력값으로 사용하기 때문에 층을 쌓는 효과를 얻어야 한다. 선형함수  $h(x) = cx$ 를 활성함수로 N층을 구성한다면  $y(x) = h^n(x) = c^n x$ 처럼 n번의 곱셈을 수행하지만 실질적으로  $y(x) = ax$ 와 똑같은 식이다. 즉 히든레이어가 없는 네트워크로 표현할 수 있다. 그래서 층을 쌓는 혜택을 얻고 싶다면 활성함수로는 반드시 비선형함수를 사용해야 한다.

활성함수를 변경했을 때 다음과 같은 예측 결과를 얻었다.

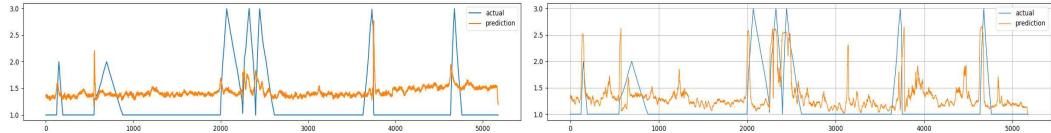


그림 29 Sigmoid와 Hyperbolic Tangent로 설정했을 때 예측 결과

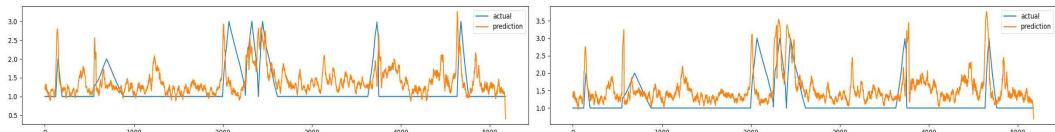


그림 30 Leaky ReLU와 ELU로 설정했을 때 예측 결과

활성함수를 ReLU로 했을 때 가장 좋은 결과를 얻을 수 있었다.

Sigmoid의 경우에는 [그림 5]에서 볼 수 있듯이 Sigmoid는 -5보다 작거나 5보다 큰 경우에는 그래디언트 값이 지나치게 작아져 학습이 잘 안되거나 학습이 느려지는 문제점이 있었기 때문에 좋은 결과를 내지 못했다고 생각할 수 있다.

Hyperbolic Tangent는 [그림 7]의 개형을 살펴보면 시그모이드 함수와 마찬가지로  $x$ 가 -5보다 작거나 5보다 크면 그래디언트가 0으로 작아지는 점을 볼 수 있다. 그래서 소멸되는 문제점이 있다. 그래서 좋은 결과를 내지 못했다고 판단된다.

이상치를 처리한 와이어의 속도 [그림 24]를 보면 이상치를 처리했지만 데이터가 미처 가공되지 못했거나 라벨링 과정에서의 정확한 계산을 못한 부분에서 발생한 데이터 때문에 속도가 음의 값이 보임을 알 수 있다. 카메라가 일정 구간 앞으로 갔다가 다시 뒤로 돌아오기 때문에 발생한 데이터로 미처 전처리 되지 못한 값들이다. 향후 연구에서 장비의 개선으로 이 문제가 해결될 것으로 보이지만 이 연구에서는 미처 처리되지 못한 값들이 남아있는 모습을 보인다. 이 값들은 활성함수 ReLU를 거쳤을 때 해당 노드가 활성화되지 않았기 때문에 더욱 좋은 결과를 얻을 수 있었다. 그래서 ReLU와 비슷한 성질을 가졌지만 음의  $x$  구간에서 노드를 비활성화시키지 않는 Leaky ReLU보다 더욱 좋은 결과를 얻을 수 있었던 것이라 생각된다. 같은 이유로 ELU보다도 더 좋은 예측 결과를 얻을 수 있었다. 학습 데이터와 상황에 맞는 적절한 활성함수 선택을 통해 더욱 좋은 결과를 도출할 수 있음을 확인할 수 있었다.

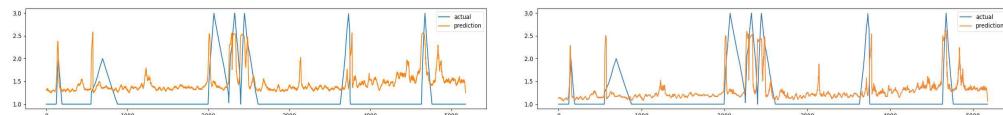
#### 4.4.2 드랍아웃을 변경했을 때의 학습 결과

다음으로 드랍아웃을 변경하며 학습해보았다. 드랍아웃을 각각 0.5, 0.3, 0.2, 0.1로 했을 때의 Loss는 0.4591, 0.4387, 0.4320, 0.4223으로 나타났다.

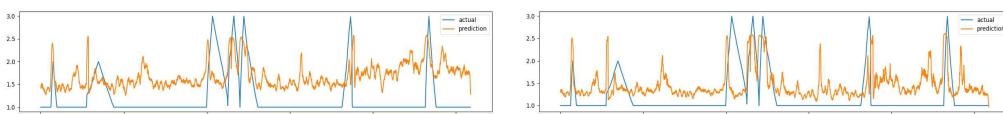
드랍아웃을 적용했을 때는 결과가 오히려 좋지 않았다. 드랍아웃은 데이터가 많아서 과적합을 해결하거나 많은 양의 데이터를 빠르게 학습시킬 필요가 있을 때 적용하면 좋은 결과가 나온다. 하지만 이번 연구에서는 데이터가 약 1만 5천개로 데이터가 많은 편이 아니기 때문에 드랍아웃을 적용했을 때 오히려 결과가 좋지 않음을 알 수 있다. 활성함수를 ReLU로 설정하고 드랍아웃은 적용하지 않았을 때 가장 좋은 결과가 나옴을 확인할 수 있다.

**표 8** 드랍아웃을 변경했을 때 각각의 Loss 결과

드랍아웃	Loss
0.5	0.4591
0.3	0.4387
0.2	0.4320
0.1	0.4223



**그림 31** 드랍아웃을 0.5, 0.3으로 설정했을 때 예측 결과



**그림 32** 드랍아웃을 0.2, 0.1로 설정했을 때 예측 결과

## 4.5 최적의 모델을 활용한 학습 결과

레이어는 1단, 활성함수는 ReLU, 드랍아웃은 적용하지 않았을 때 가장 좋은 결과를 얻을 수 있었다. 파라미터 튜닝을 한 모델을 통해 학습하였을 때 Loss는 0.3752로 72.64%의 정확도를 얻었다.

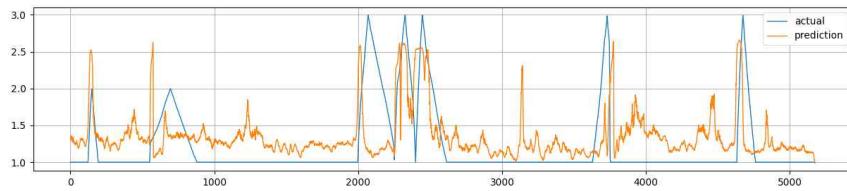


그림 33 파라미터 튜닝을 한 모델 학습 결과

데이터를 가공하면서 속도(Velocity)와 암등급이 가장 연관이 있을 거라 생각을 했고 실제로 Correlation Coefficient를 구해보았을 때도 암등급과 가장 관련이 깊은게 속도로 나타났다. LSTM을 이용한 모델에서도 속도, 피드압, 회전압 순으로 반영이 되었을 것이라 판단할 수 있다.

라벨링의 정밀도를 높일 수 있었다면 오차들을 줄일 수 있었을 것이다. 이번 연구에서 라벨링은 PLHBM에서 얻어진 데이터와 연구실에서 제작한 특수 카메라 장비를 이용한 3차원 영상을 보고 직접 거리에 따른 암등급을 판단하였다. 이렇게 각각 따로 측정된 데이터를 병합하는 과정에서 발생한 오차가 있을 수 있다. 매핑할 때 일치하는 거리가 없는 경우 보간법을 사용하여 거리를 매핑하였기 때문에 근처 구간의 암등급이 일정하다면 큰 오차가 없었겠지만 암등급이 변하는 구간에서는 정확한 거리에 따른 암등급이 반영되지 않았을 수 있다. 그래서 그림 N에서 보는 것과 같이 실제값과 예측 결과 사이에 편차가 일정하지 않음을 알 수 있다. 2000~2500번째 구간에서는 왼쪽으로 편향되었고 3800번째 구간에서는 오른쪽으로 편향되었다. 그리고 100번째 구간에서는 정확하게 일치하였다. 그리고 카메라의 영상을 보고 암등급을 판단할 때 애매모한 부분이 있어서 주관적인 판단요소가 들어갔다. 최대한 일관되게 암등급을 판별하려고 하였지만 항상 정확하게 평가하는 데 한계가 존재하였다. 그리고 영상 이미지를 보고 거리에 따른 암등급을 라벨링 할 때 거리 데이터를 정밀하게 얻기는 힘들었다. 카메라의 이동속도를 예측하여 거리를 수치화하였기 때문에 정확한 수치화가 이루어지지 않았다면 이 과정에서도 오차가 발생하였을 것이다.

데이터의 양이 많았더라면 더욱 정밀한 결과를 얻을 수 있었을 것이다. [그림 33]을 보면 예측한 데이터와 실제 데이터 사이의 전체적인 흐름은 거의 비슷하고 암등급의 결과가 조금씩은 다름을 알 수 있다. 학습 데이터가 더 많았더라면 더 높은 정확도로 결과를 예측할 수 있었을 것이다. 데이터의 부족 문제는 다른 지역의 PLHBM이 이루어졌을 때 데이터를 얻어 결과값들을 축적하면 전체적인 정확도와 정밀도가 향상될 것이므로 향후 연구들이 추가로 이어진다면 더 좋은 결과를 얻을 수 있을 것이다.

## 제5장 결론

선대구경 발파공법 시 획득한 천공 데이터와 천공작업 후 촬영한 천공홀 내부 영상을 통해 얻은 암반 특성 데이터를 인공지능을 활용해 전방 지질 상태를 예측하였다.

전방 지질 상태는 인공지능 기법 중 하나인 LSTM을 통해 측정하여 72.64%의 높은 정확도로 예측할 수 있었다. LSTM은 RNN보다 더 긴 의존 기간을 필요로 하는 학습을 수행할 능력을 갖고 있다.

발파를 위해서 진동저감과 높은 발파 효율을 위해서 공정상 천공이 필수적이다. 점보드릴은 평균 천공거리가 3~5m인 반면 선대구경은 50m 정도이다. 발파의 굴진장은 2~3m이므로 점보드릴을 이용한 천공에서는 암등급 예측이 현장에서는 크게 도움이 되지 않지만 선대구경 천공에서는 암등급 예측은 앞으로 남은 발파가 많으므로 미리 대응할 수 있기 때문에 도움이 많이 된다.

연구를 통해서 선대구경 발파공법이 천공에만 그치는 것이 아니라 전방 지질 상태를 높은 정확도로 예측할 수 있음을 확인하였다. 추가적인 비용 지출 없이, 빠른 시간 내에 암등급을 예측할 수 있기 때문에 현장에서 효과적으로 사용될 수 있다. 이번 연구를 하면서 만든 전처리 파이썬 코드를 활용하여 선대구경 발파공법 시 획득한 천공 데이터를 전처리하고 인공지능 학습 모델을 활용한다면 현장에서 터널면 암등급 결과를 실시간에 가깝게 추정할 수 있다. 실시간으로 알아낸 터널면 암등급을 통해 선대구경 발파 효율을 올릴 수 있고 암등급 데이터를 몰라서 발생할 수 있는 사고 또한 미리 예방할 수 있을 것으로 예상된다.

하나의 지역에서의 천공 데이터만을 가지고 연구를 수행하였다. 다른 지역에서 수행된 천공 데이터와 천공 후 내부 영상 데이터가 축적된다면 암등급의 예측 정확도는 증가할 것이다.

암등급을 라벨링할 때 정확한 거리를 알기 어려웠다. 영상을 통해서 예측한 속도로 거리를 추산하여 데이터를 만들었지만 영상 장비를 개선하여 정확한 거리에 따른 이미지를 얻을 수 있다면 데이터의 오차가 없으므로 정확한 예측이 가능할 것이다.

그리고 내부 영상 데이터를 최대한 정확하고 일관되게 등급을 매기려고 노력하였지만 1만 5천 여개의 많은 데이터를 라벨링하는 과정에서 오차가 있을 수 있다고 생각한다. 천공 후 내부 영상을 라벨링 과정을 클러스터링, GAN과 같은 비지도학습을 사용하여 라벨링한다면 보다 정확도를 높일 수 있을 것이다.

## 참고문헌

백종현, 백상현, 한동훈, 원아람, 김창섭. (2012). 기술사례 : 선대구경 수평보링 발파공법(PLHBM)의 설계 연구. *화약발파*, 30(2), 66-76.

이제겸. “천공 모니터링 데이터와 LSTM 기반의 머신러닝 기법을 활용한 굴착면 전방 지질예측에 관한 연구.” *국내석사학위논문* 한양대학교, 2021. 서울

정민수. “터널굴진발파에서 정량적인 발파결과 평가기법에 대한 연구.” *국내석사학위논문* 한양대학교 대학원, 2010. 서울

터널지하공간학회, 터널굴착에 따른 소음/진동 기준 및 관련 공법 기술, 2016

이효, 손지호, 김병렬, 이승중, 김남수, 최성웅. (2019). 심발공법에 따른 발파진동 저감효과에 대한 수치해석적 연구. *화약발파*, 37(1), 1-13.

김광염, 김창용, 김광식. (2008). 균질암반에서의 유압식 천공데이터 평가. *터널과 지하공간*, 18(6), 480-490.

김해만, 이인모, 홍창호, (2019), RMR과 암석종류가 터널 천공속도에 미치는 영향

정진혁. “터널 막장전방 지질평가를 위한 선대구경 공내영상 및 천공데이터 계측시스템 개발에 관한 연구.” *국내석사학위논문* 한양대학교, 2021. 서울

Impact of Data Normalization on Deep Neural Network for Time Series Forecasting, Samit et al.

ImageNet Classification with Deep Convolutional Neural Networks, Krizhevsky et al.

Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUS), B.Xu et al.

Long Short-Term Memory (LSTM) , Sepp et al.