

선대구경 발파 데이터와
인공지능을 이용한
전방 지질 상태 예측 연구

신희지
이영훈

목차

문헌연구

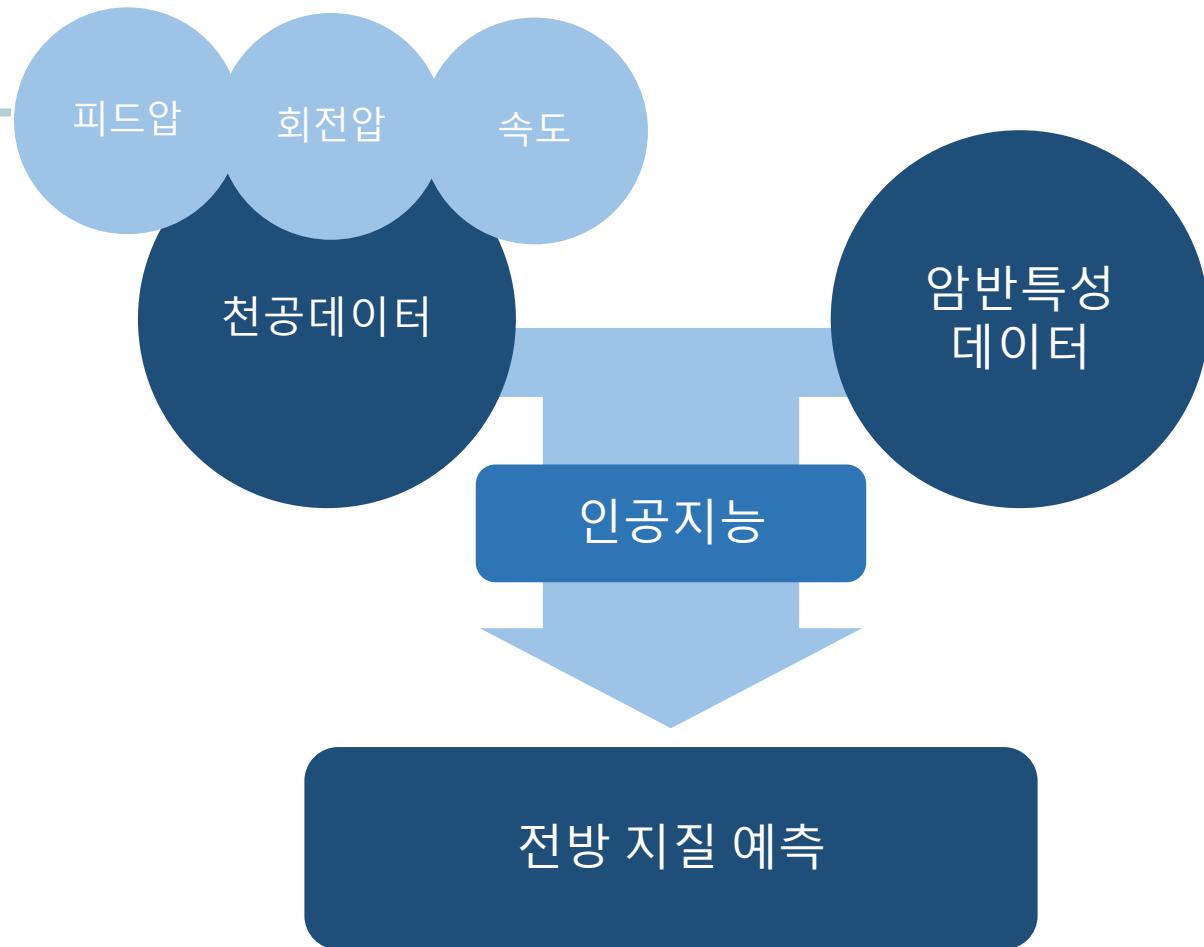
데이터분석

모델링

LSTM

결론

1. 서론



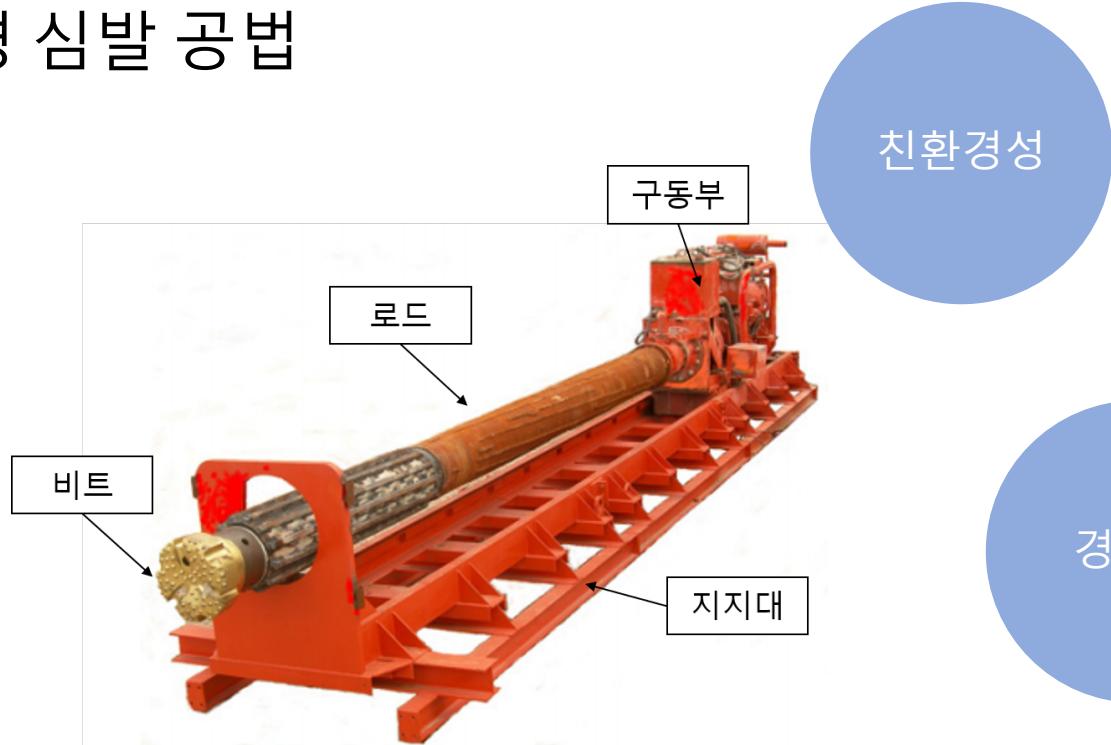
2.1~2.3 터널 발파원리



| 구분 | 일반발파 | 진동제어발파 | 정밀진동 제어발파 | 미진동 굴착공법 |
|----------------|----------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|
| 공법개요 | 1공당 최대장약량이 발파규제기준을 충족시킬 수 있을 만큼 보안물건과 이격된 영역에 대해 적용하는 공법 | 발파영향권 내에 보안물건이 존재하는 경우 “시험발파” 결과에 의해 발파설계를 실시하여 규제기준을 준수할 수 있는 공법 | 소량의 폭약으로 암반에 균열을 발생시킨 후, 대형브레이커 에 의한 2차 파쇄를 실시하는 공법 | 보안물건 주변에서 정밀진동 제어발파이내 수준으로 진동을 저감시킬 수 있는 공법으로서 대형 브레이커로 2차 파쇄를 실시하는 공법 |
| 지발당장 약량(kg) | 5.0~15.0 | 0.5~5.0 | 0.125~0.5 | 폭약기준 0.125 미만 |

* 천공깊이, 최소저항선, 천공간격 치수 등은 평균적으로 제시한 수치이며, 공사시행 전에는 시험발파에 따라 현장별로 검토, 적용하여야 함

2.1~2.3 선대구경 심발 공법



선대구경 수평심발 공법이란 굴착면 전방으로 10~60m정도 선진 보링한 직경 250~1,000mm의 대수경 수평보링공을 심발 발파시 무장약공으로 활용하는 터널 발파 공법

2.1~2.3 지질 예측 방법

② 선행연구

천공시 유압 착암기에서 얻어지는 천공 데이터로부터 지반 특성과의 직접적인 연관성을 밝혀내고 더 나아가 시공효율까지 영향이 미친다는 점이 선행연구가 수행되었다.

천공데이터 분석에 대한 연구들은 굴진면 전방의 지질을 예측하고, 지반의 안정성을 파악하는 데 활용되고 있다.

③ 결론

다만, 국내의 천공데이터 연구에서는
현재 많이 사용되는 선대구경 장비를 활용해 전방 암반 상태를 예측하는 부분이 연구된 바 없다.

2.4 데이터 정규화 (cont.)

2. Standardization Normalization

$$x_{scaled} = \frac{x - m}{\sigma}$$

(m : 평균, σ : 표준편차, x : 입력 데이터)

평균과 표준편차를 사용하여 정규화하는 방식이다
평균을 제거하고 데이터를 분산 단위로 조정한다

평균과 표준편차가 이상치에 영향을 많이 받는 단점이 존재

2.4 데이터 정규화 (cont.)

3. Robust Normalization

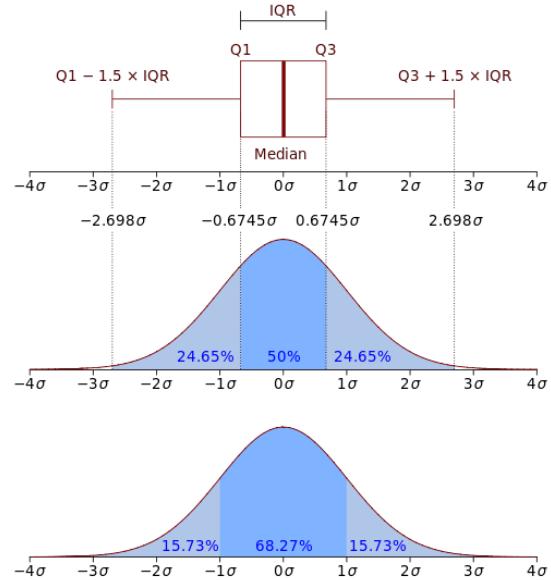
$$x_{scaled} = \frac{x - x_{2/4}}{x_{3/4} - x_{1/4}}$$

($x_{3/4}$: Q3, $x_{2/4}$: 중앙값, $x_{1/4}$: Q1, x : 입력 데이터)

중앙값과 사분위값을 사용하여 정규화하는 방식이다

아웃라이어의 영향을 최소화한 기법

(분모를 이상치를 제외한 $x_{3/4}$ 와 $x_{1/4}$ 의 차이를 사용)



2.5 활성함수

뉴런이 다음 뉴런으로 신호를 보낼 때 입력신호가 일정 기준 이상이면 신호를 보내고 기준에 미치지 못하면 보내지 않는다

이를 모방하여 적용하기 위해 신호를 보낼지 말지 결정해 주는 것이 활성함수 (Activation Function)이다

많은 종류의 활성함수가 있고 활성함수에 따라 결과가 크게 변하게 된다

2.5 활성함수 (cont.)

1. Sigmoid 함수

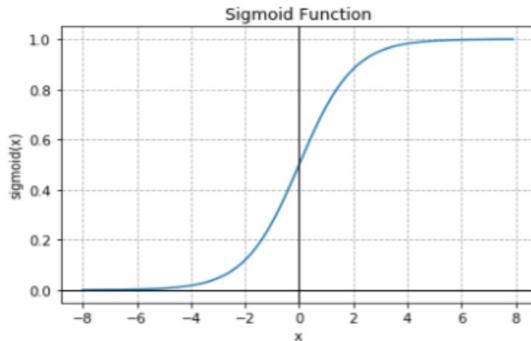


그림 5 Sigmoid Function

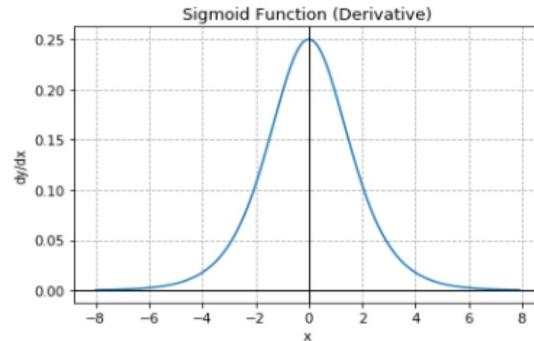


그림 6 Derivative Sigmoid Function

$$\text{Sigmoid: } \sigma(x) = \frac{1}{1 + e^{-x}}$$

Derivative Sigmoid:

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

1. 원점 중심이 아닌 문제

Sigmoid 함수는 원점 대칭이 아니기 때문에 부호가 다른 같은 크기의 입력값에 다른 결과값
 → 학습의 결과가 안 좋아질 수 있다

2. Gradient Vanishing 문제

Derivative Sigmoid에서 x값이 일정 이상 올라가면 거의 0에 수렴하게 된다
 → Backpropagation시 미분값이 소실되어 학습이 안된다

2.5 활성함수 (cont.)

2. Hyperbolic Tangent 함수

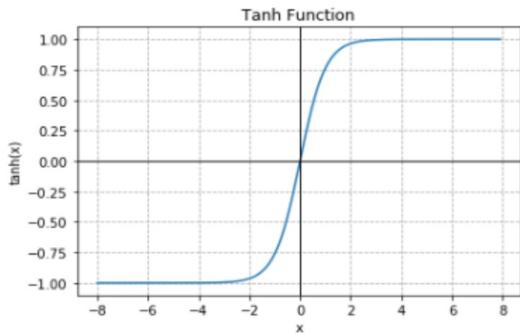


그림 7 Hyperbolic Tangent

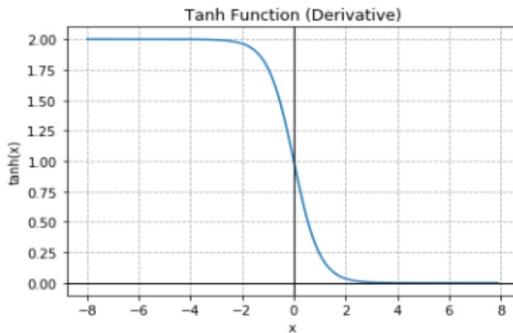


그림 8 Derivative Hyperbolic Tangent

$$\tanh: \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Derivative tanh:

$$\tanh'(x) = 1 - \tanh^2(x)$$

1. Sigmoid의 원점 비대칭 문제를 해결하였다

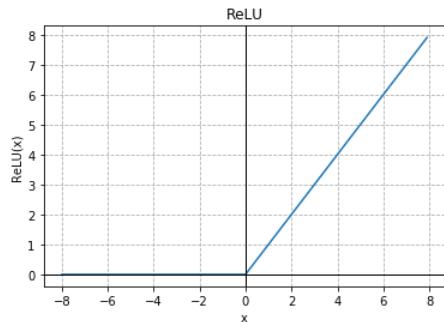
2. Gradient Vanishing 문제는 계속 있다

Derivative Sigmoid에서 x 값이 일정 이상 올라가면 거의 0에 수렴하게 된다

→ Backpropagation시 미분값이 소실되어 학습이 안된다

2.5 활성함수 (cont.)

3. ReLU 함수



$$\text{ReLU}: f(x) = \max(0, x)$$

1. 구현이 간단하기 때문에 연산의 속도가 빠르다
→ Sigmoid와 Tanh에 비해 수렴속도가 6배 더 빠르다
2. 빠른 학습이 가능하고 선대구경 발파공법 시 획득한 천공 데이터는 모두 양수이고 미처 전처리되지 못한 음수 속도 데이터는 비활성화 시켜야하기 때문에
→ 이번 연구에 적합한 활성함수 (실제로도 가장 좋은 예측 결과를 보여줌)

2.6 인공지능

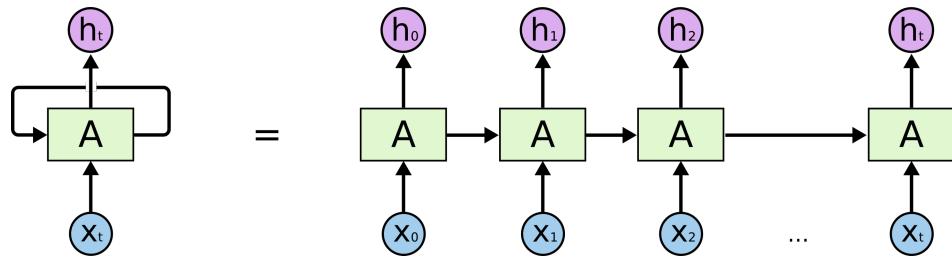
선대구경 발파공법 시 획득한 천공 데이터를 이용하여 암등급을 예측하는 인공지능 모델을 만든다

이렇게 만들어진 모델을 활용하여 천공 데이터만 있으면 전방 지질 상태를 높은 정확도로 예측할 수 있다

선대구경 발파공법 시 획득한 천공 데이터는 시계열 데이터이다
시계열 데이터는 RNN과 RNN에서 발전된 LSTM 방법을 이용한다

2.6 인공지능 (cont.)

RNN (Recurrent Neural Network)

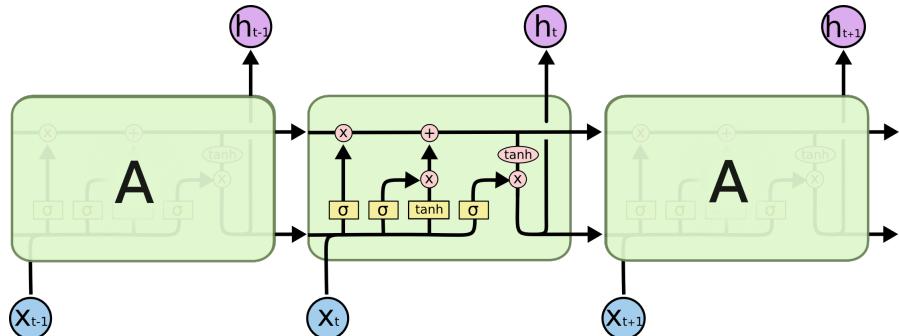


RNN은 입력으로 받은 데이터를 순전파하여 이를 다음 모델에도 함께 이용하는 구조로 되어 있다

이렇게 체인처럼 이어지는 구조의 네트워트는 연속적인 데이터를 잘 다루게 된다

2.6 인공지능 (cont.)

LSTM (Long Short-Term Memory model)



RNN은 긴 의존 기간에 대해 학습을 잘 하지 못하는 문제점이 있다

긴 의존 기간을 필요로 하는 경우 RNN은 좋지 못한 결과를 보여준다

LSTM은 긴 의존 기간을 필요로 하는 학습을 수행할 능력을 갖고 있다

3.1 현장소개

뉴스홈 | 최신기사

[르포] 3년 연속 침수 피해 영덕 강구면 주민 "이건 인재"

송고시간 | 2020-07-24 11:18



[기자 페이지](#)

| 2018년 태풍 콩레이, 2019년 태풍 미탁...
주민 "배수펌프 4대 중 1대만 가동"...가동률 50% 수준

뉴스홈 | 최신기사

영덕 강구 매년 물난리 나는데 더디기만 한 재해복구

송고시간 | 2020-07-24 17:35



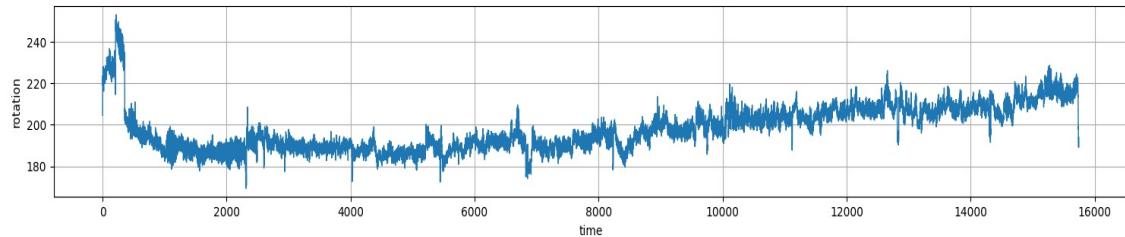
[기자 페이지](#)

| 소하천 재해복구 공정률 50% 수준...배수펌프장 증설 착공도 못 해



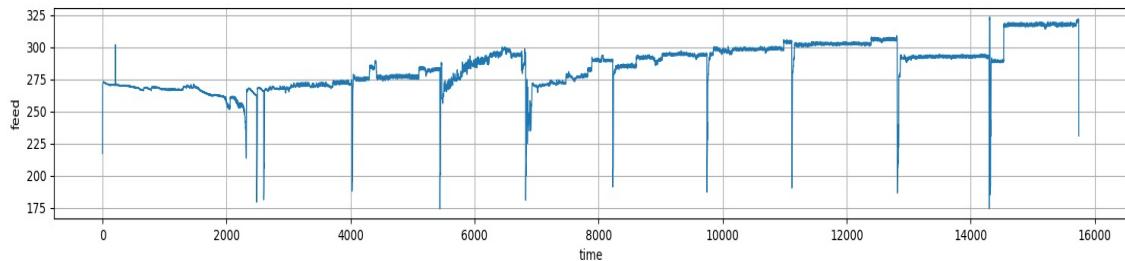
3.2 데이터 수집 및 소개

Input data



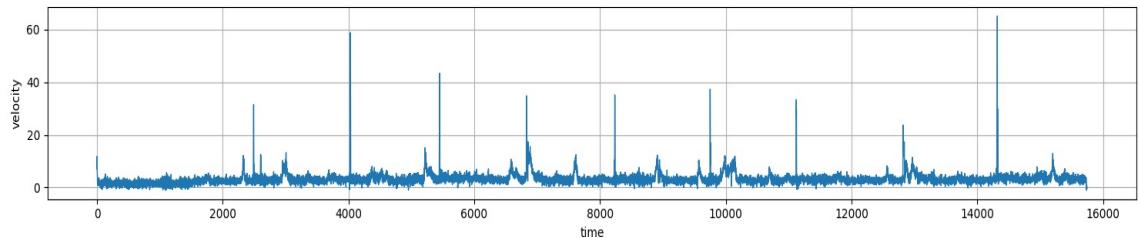
회전압 데이터

유압센서



추진압 데이터

유압센서



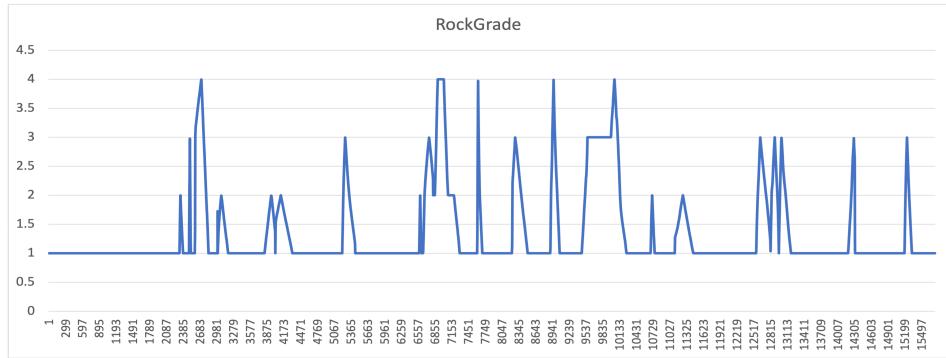
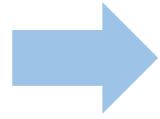
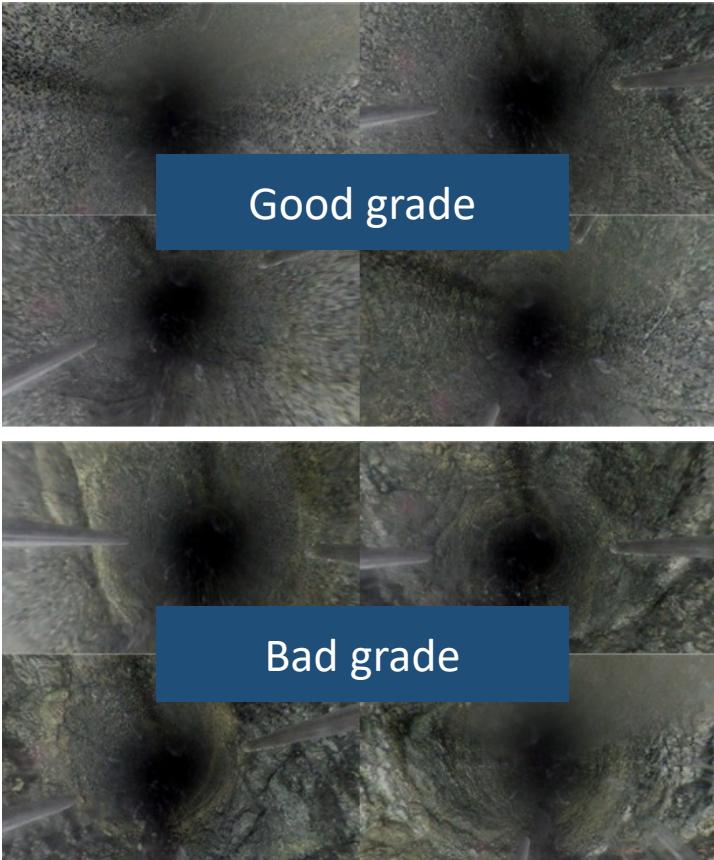
천공속도 데이터

와이어센서

3.2 데이터 수집 및 소개 (cont.)

3. 현장조사 및 데이터 수집

Output data



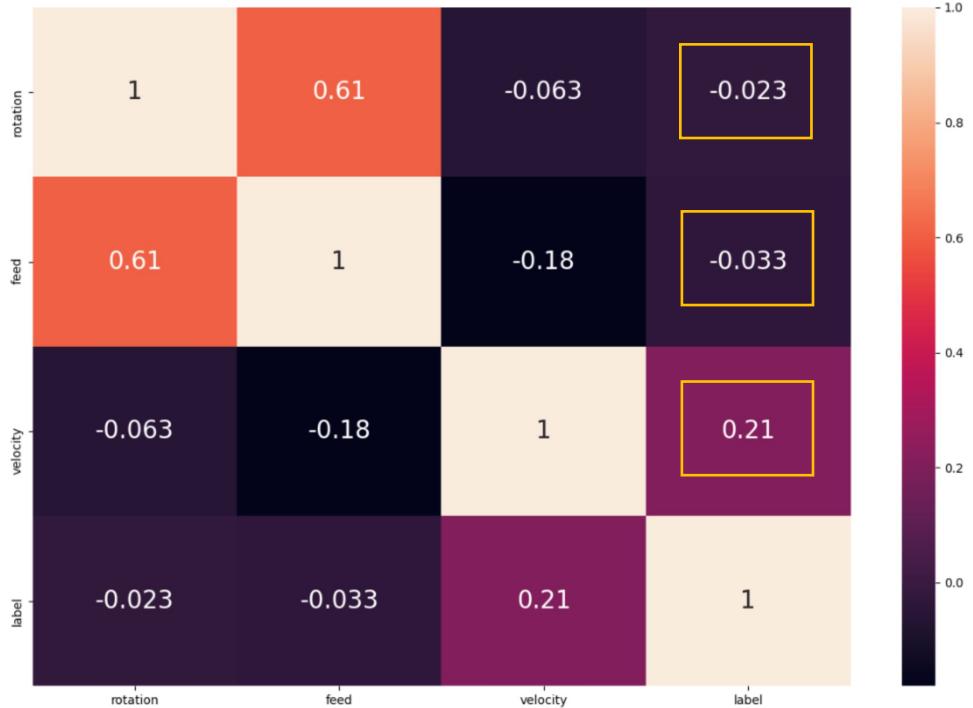
3.3 데이터 전처리

선대구경 발파공법 시 획득한 천공 데이터로 위치(p1), 속도, 회전압, 피드압을 구하였다

천공작업 후 촬영한 천공홀 내부 영상을 통해 위치(p2)와 암등급을 얻었다

이렇게 따로 얻어진 두개의 데이터셋을 위치(p1과 p2) 데이터를 통해 매핑하여 속도, 회전압, 피드압에 따른 암등급 데이터를 구할 수 있었다

3.4 상관분석



암등급과의 상관관계

1. 회전압: -0.023
2. 피드압: -0.033
3. 속도: 0.21

4.1 학습 계획

속도, 회전압, 피드압에 따른 암등급 데이터를 LSTM을 인공지능 방법을 이용하여 학습한다

더욱 높은 정확도를 위해 파라미터(활성함수, 드랍아웃)을 변경하며 최적의 학습 모델을 구해본다

4.2 데이터 가공

가공되지 않은 속도, 회전압, 피드압에 따른 암등급 데이터에는 이상치와 잡음 데이터가 많다

이상치와 불필요한 데이터를 우선 필터링하여 삭제하고 남아있는 이상치 데이터는 합리적인 범위에 들어올 수 있도록 추가 가공을 거쳤다

4.2 데이터 가공

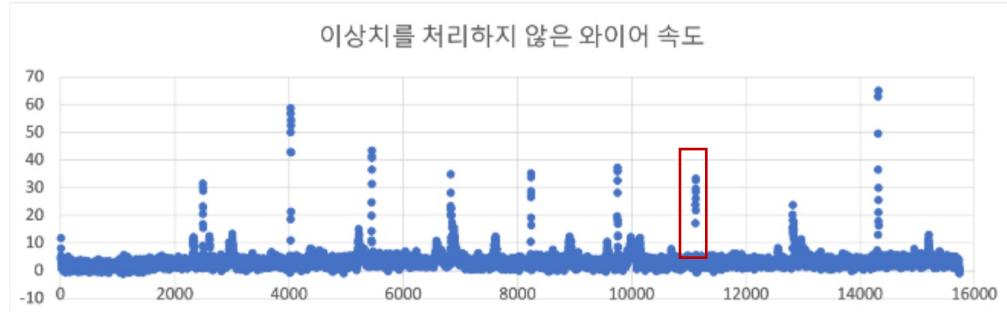


그림 23 와이어의 속도

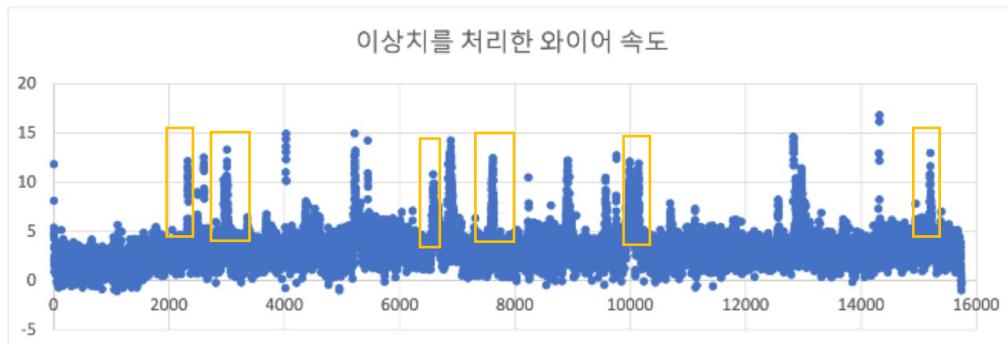


그림 24 이상치를 처리한 와이어의 속도

에는 크게 나타나지 않았던 새로운 높은 속도들을 확인할 수 있다. 이는 이상치의 영향력이 줄어들고 기존 데이터의 평균 속도가 아니었던 높은 속도들이 더욱 적으로 더욱 크게 부각되었기 때문이다. 이상치를 적극적으로 처리한 결과는 학습에 미친 결과를 미칠 것으로 예상할 수 있다.

4.2 데이터 가공

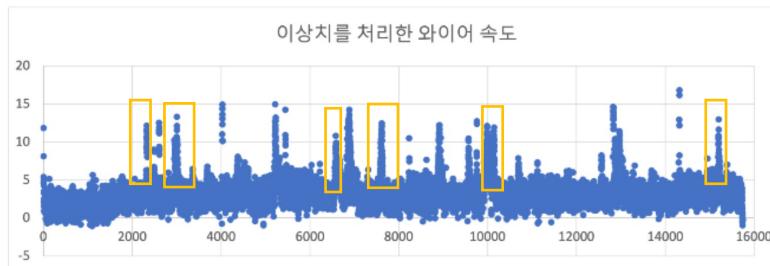


그림 24 이상치를 처리한 와이어의 속도

기존에는 크게 나타나지 않았던 새로운 높은 값들을 확인할 수 있다. ([노란색 박스](#))

이는 이상치의 데이터의 영향력이 줄어들고 기존 데이터의 이상치가 아니었던 높은 속도들이 더욱 상대적으로 더욱 크게 부각되었기 때문이다.

이상치를 적극적으로 처리한 결과는 학습에 유의미한 결과를 미칠 것으로 예상할 수 있다.

4.3 데이터 정규화



이점

- (1) 남아있는 이상치에 대한 처리
- (2) 데이터 간의 스케일의 차이를 보정

→ 빠른 학습, 모델의 더 높은 예측 정확도

4.3 데이터 정규화

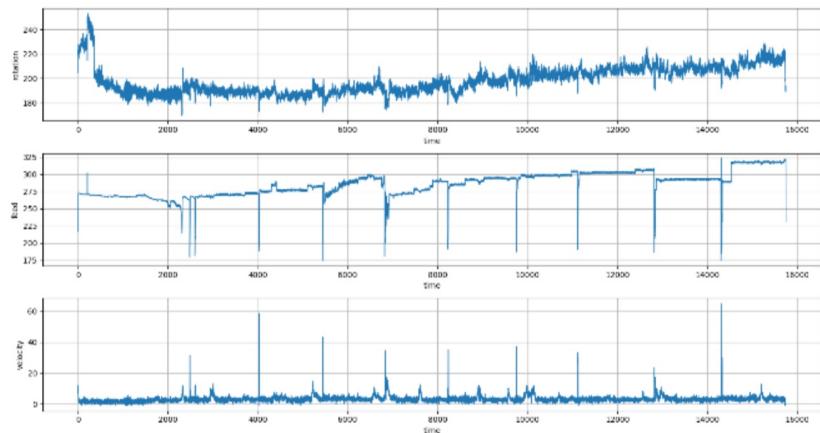


그림 25 정규화를 하지 않은 데이터

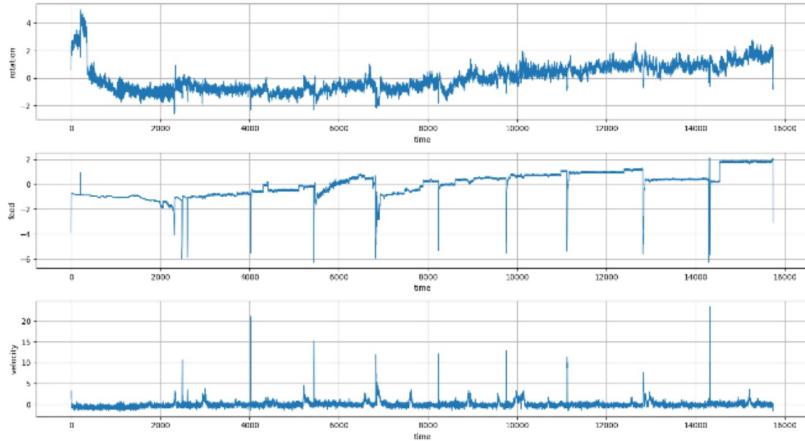


그림 28 Robust Normalization을 한 데이터

- 데이터 간의 스케일들이 비슷해졌다
정규화되지 않은 데이터의 최대 최소 축값은 325, 0이고
Robust Normalization을 거친 데이터의 최대 최소 축값은 20, -2이다
- Robust Normalization는 사분위 값 사용하기 때문에 이상치 보정이 되었다

4.4.1 활성함수를 변경했을 때 학습 결과

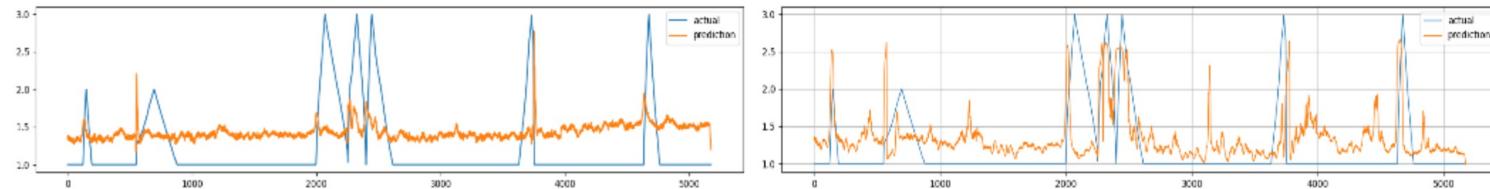


그림 29 Sigmoid와 Hyperbolic Tangent로 설정했을 때 예측 결과

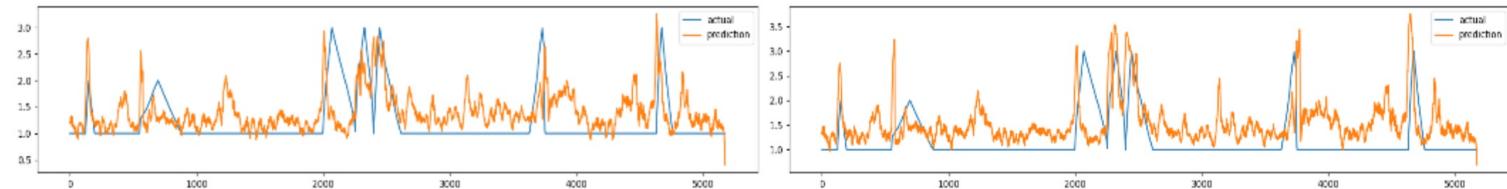


그림 30 Leaky ReLU와 ELU로 설정했을 때 예측 결과

4.4.1 활성함수를 변경했을 때 학습 결과

Loss는 Root Mean Square로 측정,
값이 작을 수록 좋은 결과

| 활성함수 | Loss |
|-----------|---------------|
| tanh | 0.3943 |
| Sigmoid | 0.5635 |
| ReLU | 0.3752 |
| LeakyReLu | 0.3922 |
| ELU | 0.3872 |

표 7 활성함수를 변경했을 때 각각의 Loss 결과

분석

1. Sigmoid와 Hyperbolic Tangent는 Gradient Vanishing 문제가 있다
2. 미처 전처리되지 못한 음수 속도 데이터는 비활성화 시켰기 때문에
ReLU가 가장 좋은 결과를 보였다

4.4.2 드랍아웃을 변경했을 때 학습 결과

Loss는 Root Mean Square로 측정,
값이 작을 수록 좋은 결과

| 드랍아웃 | Loss |
|------|--------|
| 0.5 | 0.4591 |
| 0.3 | 0.4387 |
| 0.2 | 0.4320 |
| 0.1 | 0.4223 |

표 8 드랍아웃을 변경했을 때 각각의 Loss 결과

과적합을 해결하거나 많은 양의 데이터를 빠르게 학습시킬 필요가 있을 때
드랍아웃을 적용하면 더 좋은 학습 결과가 나온다.

하지만 이번 연구에서는 데이터가 약 1만 5천개로 데이터가 많은 편이 아니기 때문에
드랍아웃을 적용했을 때 오히려 결과가 좋지 않음을 알 수 있다.

4.5 최적의 모델을 활용한 학습 결과

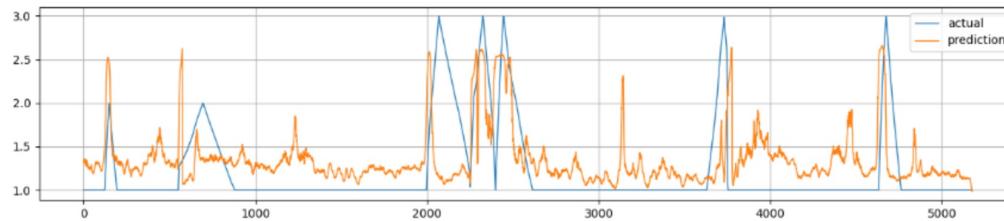


그림 35 파라미터 튜닝을 한 모델 학습 결과

활성함수: ReLU
드랍아웃: 적용 안함

→ 예측 정확도: 72.64%, Loss: 0.3752

5. 결론



연구목적

선대구경 발파공법 시 획득한 데이터와
천공작업 후 촬영한 천공홀 내부 영상을 촬영해 얻은 전방 지질 특성 데이터를
인공지능을 활용해 암등급을 예측하였다



결과

암등급을 인공지능 기법 중 LSTM을 활용하여 측정하였으며
72.64%의 높은 정확도로 예측할 수 있었다

5. 결론



현장에서의 활용

발파를 위해서는 진동저감과 높은 발파 효율을 위해서 공정상 천공이 필수적이다
점보드릴은 평균 천공거리가 3~5m인 반면 선대구경은 50m 정도이다

발파의 굴진장은 2~3m이므로 점보드릴을 이용한 천공에서는 암등급 예측이
현장에서는 크게 도움이 되지 않지만 선대구경 천공에서는 암등급 예측은
앞으로 남은 발파도 많으므로 미리 대응할 수 있기 때문에 도움이 된다

천공작업 후 촬영한 천공홀 내부 영상을 촬영해 얻은 전방 지질 특성 데이터를
인공지능을 활용해 암등급을 예측에는 (1) 추가적인 비용없이 (2) 빠른 시간내에
암등급을 예측할 수 있기 때문에 현장에서 효과적으로 사용될 수 있다

5. 결론



앞으로의 연구방향

1. 하나의 현장에서의 데이터로 암등급을 예측하였지만 다른 현장에서의 천공 데이터와 거리에 따른 암등급 데이터가 축적된다면 더욱 높은 정확도로 암등급을 예측할 수 있다.
2. 암등급을 라벨링 할 때 정확한 거리를 알기가 어려웠다.
영상을 통해서 예측한 속도로 거리를 추산하여 데이터를 만들었지만 장비를 좀 더 개선하여 정확한 거리에 따른 이미지를 얻을 수 있다면 틀린 데이터가 없으므로 더욱 정확한 예측이 가능할 것이다.
3. 내부 영상 데이터를 최대한 정확하고 일관되게 등급을 매기려고 노력하였지만 1만 5천 여개의 많은 데이터를 라벨링하는 과정에서 오차가 있을 수 있다고 생각한다. 천공 후 내부 영상을 라벨링 과정을 클러스터링, GAN과 같은 비학습지도를 사용하여 라벨링한다면 보다 정확도를 높일 수 있을 것이다.